

黑洞研究中的机器学习与深度学习应用

丁子杨, 温泽林, 刘宇昊, 陈峻松

(山东大学(威海) 山东威海 264200)

摘要: 近年来, 机器学习和深度学习技术的快速发展为黑洞研究提供了全新的分析工具与方法。本文系统综述了这些技术在黑洞天文学中的关键应用, 涵盖黑洞图像重建、参数估计、引力波信号处理及数值模拟预测等领域。此外, 本文提出了基于扩散模型的黑洞图像去噪与超分辨率重建方案, 为未来观测数据的高质量还原提供了新思路。现有方法仍需解决模型泛化性、可解释性及小样本学习等挑战。未来研究可结合大语言模型(LLM)的多模态理解能力, 进一步推动黑洞多信使数据的融合分析与跨领域知识挖掘, 为揭示极端天体现象的本质规律提供技术支撑。

关键词: 黑洞 机器学习 引力波 生成对抗网络 事件视界望远镜

The Application of Machine Learning and Deep Learning in Black Hole Research.

Ziyang Ding, Zelin Wen, Yuhao Liu, Junsong Chen

(School of Mathematics and Statistics, Shandong University, Weihai, 264209, China)

Abstract: In recent years, the rapid development of machine learning and deep learning techniques has provided new analytical tools and methods for black hole research. This paper systematically reviews the key applications of these technologies in black hole astronomy, covering areas such as black hole image reconstruction, parameter estimation, gravitational wave signal processing, and numerical simulation prediction. Furthermore, this paper proposes a black hole image denoising and super-resolution reconstruction scheme based on diffusion models, providing new ideas for high-quality restoration of future observational data. Existing methods still need to address challenges such as model generalization, interpretability, and few-shot learning. Future research can combine the multi-modal understanding capabilities of large language models (LLMs) to further promote the fusion analysis of black hole multi-messenger data and cross-domain knowledge mining, providing technical support for revealing the essential laws of extreme astronomical phenomena.

Keywords: Black hole, Machine learning, Gravitational waves, Generative adversarial network, Event horizon telescope.

目录

黑洞研究中的机器学习与深度学习应用	1
1 概述	5
2 黑洞的奥秘	6
2.1 黑洞是什么	6
2.2 黑洞的分类	7
2.3 黑洞的吸积、喷流和合并过程	8
2.4 引力波	10
2.5 黑洞观测	12
3 深度学习技术介绍	14
3.1 多层感知机（MLP）	14
3.2 卷积神经网络（CNN）	14
3.3 长短期记忆网络（LSTM）	15
3.4 双向长短期记忆网络（Bi-LSTM）	15
3.5 时序卷积网络（TCN）	15
3.6 Transformer	15
3.6.1 基本结构	16
3.6.2 自注意力机制（Self-Attention）	16
3.6.3 多头自注意力（Multi-Head Attention）	17
3.6.4 位置编码（Positional Encoding）	17
3.6.5 前馈神经网络（Feed-Forward Networks）	18
4 引力波分析	19

4.1 引言	19
4.2 研究进展	19
4.2.1 传统方法	19
4.2.2 CNN.....	21
4.2.3 CNN + 其余模型结构	22
4.3 未来展望	24
5 射电波分析	25
5.1 引言	25
5.2 研究进展	25
6 黑洞参数估计	27
6.1 引言	27
6.2 研究进展	27
6.3 未来展望	28
7 大模型方案	29
7.1 已有研究总结	29
7.2 扩散模型	30
7.2.1 模型基础结构	31
7.2.2 模型调整	32
7.3 未来展望	32
7.3.1 大模型在黑洞研究的潜力	32
7.3.2 大模型面临的挑战	33
8 大模型辅助理解方法	34

8.1 多类 LLM 对比.....	34
8.2 借助 ChatPDF 理解论文/Prompt pipeline.....	36
8.2.1 导入 PDF 文件.....	37
8.2.2 构建 prompt pipeline.....	37
8.3 各领域论文汇总	44
8.4 思维导图生成	45
参考文献.....	47

1 概述

黑洞研究是现代天文学和物理学领域的关键课题，其独特的物理特性为探索宇宙奥秘提供了重要窗口。自爱因斯坦广义相对论奠定理论基础以来，黑洞研究历经重大发展，从理论预测到观测验证，不断深化人类对宇宙极端天体现象的认知。

在黑洞研究过程中，机器学习技术的引入成为重要革新力量。传统的黑洞研究方法，如基于广义相对论的理论推导和天文观测数据的分析，虽取得诸多成果，但面对复杂的黑洞数据，如黑洞图像、引力波信号等，存在一定局限性。机器学习技术凭借强大的数据处理和模式识别能力，为黑洞研究带来新的思路与方法。

目前，应用于黑洞研究的机器学习技术主要分为多种类型，包括多层感知机(MLP)、卷积神经网络(CNN)、长短期记忆网络(LSTM)及其变体双向长短期记忆网络(Bi-LSTM)、时序卷积网络(TCN)以及 Transformer 等。MLP 作为基础的前馈神经网络，能在黑洞相关的回归和分类任务中发挥作用，如对黑洞图像按物理特征分类以及进行特征选择和数据降维。CNN 则在图像处理领域优势显著，在黑洞研究中，尤其在黑洞图像重建和处理方面表现突出。LSTM 适合处理时间序列数据，可用于分析黑洞周围时变信号，识别黑洞活动模式，Bi-LSTM 在此基础上能更好地捕捉序列前后依赖关系，在分析双黑洞合并等事件时更具优势。TCN 专为时间序列数据处理设计，可用于分析黑洞附近喷流或吸积盘的变化。

Transformer 架构近年来在自然语言处理领域成果斐然，在黑洞研究中也展现出巨大潜力。它基于自注意力机制和前馈神经网络，能够并行计算并捕捉全局依赖。在黑洞研究中，Transformer 可用于处理与黑洞相关的复杂序列数据，例如在引力波信号分析中，结合其他技术实现对信号的高效去噪和检测。

本文详细介绍了各类应用于黑洞研究的机器学习技术，以及基于这些技术的改进算法和应用案例，分析了它们在黑洞研究中的优势、改进之处以及存在的不足。还探讨了这些技术在黑洞研究多领域的创新应用，如结合多源数据进行联合分析等。这些成果展示了机器学习技术在黑洞研究领域的重要价值，希望能为未来黑洞研究的深入开展和实际应用提供有力参考，推动人类对黑洞这一神秘天体的进一步认识。

2 黑洞的奥秘

2.1 黑洞是什么

黑洞理论的演进深刻反映了人类对时空本质认知的突破性进展。这一概念最早可追溯至 1783 年，英国自然哲学家约翰·米歇尔（John Michell）基于牛顿力学提出“暗星”假说，计算出当天体逃逸速度超过光速时将成为不可见引力源。尽管这一思想在拉普拉斯的数学推演中初具雏形，但受限于经典物理框架的局限性，直到爱因斯坦 1915 年建立广义相对论后才获得革命性重构。史瓦西（Karl Schwarzschild）在 1916 年首次求得球对称真空解，揭示时空曲率在临界半径处趋于无穷的奇异特性，但彼时学界对其物理意义存在长达数十年的争议。随着奥本海默 1939 年建立恒星引力坍缩的动力学模型，以及克尔（Roy Kerr）1963 年发现旋转黑洞精确解，理论物理学家逐渐认识到这些数学解并非抽象概念，而是大质量恒星演化的必然归宿。至 1967 年约翰·惠勒（John Wheeler）正式命名“黑洞”时，其作为引力奇点的时空结构已在彭罗斯的因果结构理论中获得了严格的几何诠释。

现代黑洞理论的核心支柱——无毛定理的形成，标志着经典广义相对论与量子物理的深度交融。该定理经由霍金、卡特等人在 1970 年代的严格证明，揭示稳态黑洞仅由质量、角动量和电荷三个参数完全表征。这一结论源于爱因斯坦场方程在事件视界边界条件下展现出的非凡简并性：任何高阶多极矩或微观结构信息都将在引力辐射过程中耗散殆尽。微分拓扑学分析表明，四维时空中仅存在克尔-纽曼解及其退化形式两类稳定黑洞解，这一特性在 2012 年数值相对论的大规模模拟中得到验证——任意非对称初始扰动最终都会辐射掉非守恒量，回归标准解形态。然而近年弦论框架下的 AdS/CFT 对应研究表明，某些高维时空构型可能允许“量子毛发”存在，这为突破经典无毛定理、探索量子引力效应提供了新的理论切入点。

事件视界作为黑洞最本质的特征，其物理内涵持续推动着观测技术的革新。这个由彭罗斯严格定义的因果边界，不仅是物质单向流动的分界面，更承载着深刻的热力学属性：贝肯斯坦（Jacob Bekenstein）1972 年提出视界面积与熵的对应关系，霍金随后通过量子场论方法推导出黑洞具有温度 $T = \hbar c^3 / (8\pi k G M)$ 的热辐射特性。现代多信使天文学通过多维度手段验证视界存在——甚长基线干涉阵（VLBI）对银河系中心 Sgr A* 周围恒

星轨道的亚毫角秒级追踪，证实 400 万太阳质量集中在史瓦西半径千分之一的空间内；LIGO 探测到的引力波信号中特征性的“铃荡衰减”模式，与克尔黑洞并合过程的数值模拟高度吻合；X 射线能谱分析揭示吸积盘内边缘振荡频率与最内稳定圆轨道（ISCO）的理论预测精确一致。2019 年事件视界望远镜（EHT）首次捕获 M87 星系中心黑洞的阴影图像，其直径与广义相对论预言偏差小于 10%，为视界的存在提供了直接视觉证据。

2.2 黑洞的分类

现代空间物理科学研究已经证实表明，我们的宇宙中有大量的黑洞，科学家们根据两种分类方式将黑洞分成了不同的种类。

按照黑洞的质量大致可以将黑洞分为三个种类：



图 1 黑洞种类

1) 恒星级黑洞（Stellar black hole）的质量约在 $10^2 M_{\odot}$ （ M_{\odot} ：太阳质量，约为 2×10^{30} 千克）以下，一般认为是由于恒星能量耗尽后，由于压力不足以抵抗自身引力向内坍缩形成中子星等致密星体，且此时质量仍然超出奥本海默-沃尔科夫极限[1]（约 $3-4 M_{\odot}$ 之间），进一步塌缩形成恒星级黑洞。

2) 超大质量黑洞（Supermassive black hole）的质量在 $10^5 M_{\odot}$ 以上，一般认为有三种形成途径。第一种是由于恒星级黑洞经过吸积过程持续增加质量形成的，第二种认为是由星云直接塌缩且没有形成超新星的情况下形成黑洞，第三种则是认为在大爆炸瞬间高密度物质塌缩形成的原初黑洞留存至今。

3) 中等质量黑（Intermediate-mass black hole）[2]的质量在 $10^2 M_{\odot}$ 至 $10^5 M_{\odot}$ 之间。它的质量超过恒星黑洞，但远小于超大质量黑洞。然而这种类型的黑洞非常神秘，目前只能通过引力辐射的观察证明其存在，尚不清楚它是如何形成的。学界普遍有两个推测，一种认为是由于恒星级黑洞和其他的致密天体发生碰撞合并形成，另一种则是恒星密集的星团中发生失控的大质量恒星碰撞形成中等质量黑洞。

当然在超大质量黑洞之上还有特大质量黑洞，其质量在 $10^{10}M_{\odot}$ 上，目前虽有几个特大质量黑洞的候选类星体，但没有直接证据表明它们就是特大质量黑洞。

根据黑洞的自旋情况和电荷状态又可以将黑洞分为四类：

表 1：黑洞的种类对应自旋情况和电荷状态

种类	史瓦西黑洞	赖斯纳-诺德斯特龙黑洞	克尔黑洞	克尔-纽曼黑洞
是否自旋	否	否	是	是
是否带电	否	是	否	是

其中克尔-纽曼黑洞就是一般的黑洞。

2.3 黑洞的吸积、喷流和合并过程

类似黑洞、中子星、年轻恒星这样的大质量中心体，其强大的引力会捕获一些物质（如气体、尘埃、恒星碎片等），由于被捕获的物质具有初始角动量，角动量守恒会使物质不会直接坠入中心体，而是形成一个旋转的盘状结构,即吸积盘（Accretion disk）[3]。

其中的物质（如气体，尘埃，恒星碎片等）主要以流体形式存在，磁旋转不稳定性（MRI）会导致盘内的磁场线扭曲，形成涡旋，从而产生湍流（Turbulence），湍流导致盘内的物质混合和能量传输，增加了物质向中心体运动的效率。湍流还产生了粘滞性（Viscosity），它是流体内部的一种阻力，表现为流体层之间的相对滑动时产生的内摩擦力。粘滞性使得流体在剪切力的作用下变形时，内部各层之间产生摩擦，从而消耗能量。粘滞性使物质逐渐失去角动量，向内螺旋运动。

根据不同的物理条件，吸积盘可以分为标准薄盘、厚盘、细盘和平流主导的吸积流（ADAF）等模型。下面是吸积盘模型比较表：

表 2：吸积盘模型比较表

类型	描述	主要特征	适用场景	参考文献
标准薄盘	物质在盘内通过粘滞性逐渐向内	盘的厚度相对于其半径非常小，	年轻恒星的原行星盘，活动星系核中	Shakura, N. I., & Sunyaev, R. A.

	螺旋运动	释放大量辐射	的吸积盘	(1973)[4]
厚盘	物质在高吸积率下形成的较厚的盘	盘的厚度较大，适用于高吸积率的情况	伽马射线暴活动星系核中的某些情况	Abramowicz, M. A., et al. (1978)[5]
细盘	物质在极高吸积率下形成的盘	辐射压力变得非常重要，适用于极端吸积情况	超大质量黑洞的极端吸积情况	Abramowicz, M. A., et al. (1988)[6]
ADAF	物质在低吸积率下形成的盘	能量主要通过平流带走，温度高但辐射效率低	银河系中心的超大质量黑洞 Sgr A，低光度活动星系核	Narayan, R., & Yi, I. (1994)[7]

在所有黑洞质量尺度上，吸积黑洞和相对论喷流之间存在很强的观测联系,吸积盘中的物质接近中心体时，部分物质会被加速并沿中心体的自转轴方向高速喷出，形成喷流（Jet）。喷流的主要特征有高速，准直，高能。Bridle & Perley （1984）对银河系外喷流的定义之后，我们使用术语“喷流”来指代具有开口角 $\leq 15^\circ$ 的准直喷射物[8]。

喷流的形成主要由吸积盘中的磁场驱动。磁旋转不稳定性（MRI）导致盘内的磁场线扭曲，产生湍流，进而增强磁场的强度。磁场线的重新连接（磁重联）可以释放巨大的能量，进一步加速喷流中的粒子。此外，高温气体在盘内产生的热压梯度也可以推动物质沿自转轴方向喷出。

喷流的观测特征主要包括多波段辐射和喷流结构。多波段辐射中涉及射电波辐射、光学辐射、X射线和伽马射线。喷流中的电子在磁场中同步加速，产生射电波辐射；喷流中的高能电子与光子相互作用，产生光学辐射；喷流中的高能粒子通过逆康普顿散射和同步加速辐射，产生X射线和伽马射线。喷流结构方面，喷流的核心部分高度准直，速度最快，能量最高；喷流的外层部分相对较宽，速度较慢，能量较低。

此外通过射电望远镜来观测喷流为研究黑洞提供了极大的便利，也带来很多具体的科学成果,如类星体（Quasars）和射电星系中的喷流，这些喷流在射电波段尤为明显。

激光干涉引力波天文台（LIGO）在 2015 年间首次发现了双黑洞合并的产生的引力

波，证实了爱因斯坦广义相对论的重要预言。

黑洞强大的引力不仅会捕获周围的物质，也会吸引黑洞。当两个黑洞在同一个星系或密集星团中相遇并形成双黑洞系统时，它们会在一个共同的轨道上绕彼此旋转。

在双黑洞系统的演化过程中，黑洞在绕行时会发射引力波。引力波是根据爱因斯坦广义相对论预言的时空扰动，会带走系统的能量和角动量。随着引力波的不断辐射，双黑洞系统的轨道逐渐收缩，轨道周期缩短。取决于初始轨道的大小和黑洞的质量，这一过程可以持续数百万年甚至数十亿年，当双黑洞系统的轨道半径缩小到一定程度时，会进入的阶段称为“快速 inspiral”阶段。此时两个黑洞之间的距离迅速减小，轨道周期急剧缩短，引力波的频率和幅度显著增加。

当两个黑洞的距离足够近时，它们的视界开始重叠，最终合并成一个更大的黑洞。这一瞬间释放出巨大的能量，主要以引力波的形式辐射出去。合并过程中，黑洞会经历一个短暂的不稳定状态，形成一个“环状结构”（ringdown）。在这个过程中，黑洞会通过发射引力波逐渐稳定下来，最终成为一个静态的、旋转的克尔黑洞。

如果合并发生在吸积盘或其他物质环境中，合并过程中可能产生强烈的喷流和电磁辐射。这些现象可以在多个波段（如射电、光学、X 射线）被观测到，为科学家提供了研究黑洞合并的多项天文学数据。这些观测数据不仅验证了广义相对论的预测，还为理解黑洞物理、星系演化和宇宙学提供了重要线索。

2.4 引力波

2015 年，LIGO 利用先进 LIGO (aLIGO) 探测器[9]首次直接观测到双黑洞合并产生的引力波（Gravitational Wave, GWs）[10]。LIGO 和 VIRGO 在随后的观测运行中对来自类似系统的引力波进行了多次观测[11]。这些发现极大地推动了引力波物理学的发展，表明引力波在黑洞物理学领域具有不可替代的重要作用。本部分将对引力波的基本理论、探测方法及机器学习和深度学习在其中的应用等进行详细阐述。

在广义相对论中，引力波被描述为时空的涟漪。类似于将石头投入池塘时在水面上产生的波纹，当带有质量的天体发生剧烈运动（如加速运动、合并等）时，也会在时空结构中引发波动。根据广义相对论，像中子星和黑洞这样的致密天体会显著弯曲周围的时空结构。当这些天体发生形状或运动的变化时，会引起时空的波动，而这种波动会以

光速向外传播。这种随时空变化而传递的波动被称为引力波[12]。它不仅反映出源头天体的物理特性，也为我们提供了观测宇宙极端天体现象的全新途径[13]。

然而，探测引力波却异常困难，因为它们会引起非常小的扭曲：即使是来自天体物理事件的最强引力波，预计也只会产生 10^{-21} 数量级的相对长度变化[14]。探测引力波的实验始于 20 世纪 60 年代韦伯和他的共振质量探测器[15]。相互作用的黑洞、凝聚的紧凑双星系统、恒星坍缩和脉冲星等都是可能的探测对象[16]，观测可能发出的引力波将极大地促进我们对宇宙的了解。传统的引力波探测基于以下理念：引力波可被视为空间中随时间变化的应变，具有两种线性极化状态（ h_+ 和 h_\times ）。当引力波经过空间中的测试块时，会引起测试块的位移。对测试质量相对位移的测量就是对引力波的测量。引力波对电磁场（如电容或激光光场）起作用。由于位移非常小，引力波的动量一般受到不确定性原理的限制。量子极限对未来的探测器是一个重大但并非不可逾越的障碍[17]。

当前已经产生多种引力波检测的方法和机器：LIGO 引力波探测器为改良的迈克尔逊干涉仪，通过测量正交臂的长度差异，来探测引力波应变[10]；美国航天局和欧洲航天局联合提出了一项空间发射计划，在太阳系轨道上放置三台激光转发器，组成一个空间激光干涉仪，用于引力波探测，拟议中的激光干涉仪空间天线（LISA）将部署在一个特定的太阳轨道上，由三个航天器组成的阵列构成。这些航天器之间通过激光互相连接，形成三个独立的迈克尔逊干涉仪。每束激光的入射光与出射信号的相位进行比较，这种比较（称为跳动测量）可以检测到激光波长的微小变化。同样的测量在另一束激光所在的另一臂中进行[10]；还可以通过对分离物体的多普勒跟踪来观测流逝引力波的潮汐效应：通过对航天器进行多普勒跟踪，可以将地球和行星际航天器用作测试块[16]；通过比较地面站发出的近乎单色的微波信号和航天器发出的相干返回信号，监测它们的相对位置等等[18]。

值得注意的是，黑洞作为一种极其庞大的天体，通常伴随着强大的引力场和激烈的天体物理活动。因此，黑洞周围往往会产生频繁的引力波现象，成为研究引力波的理想对象，并由此推动了大量相关研究的开展：Masamune Oguri 研究引力透镜对来自遥远双黑洞合并引力波的影响，在观测到的合并过程中啁啾质量和红移分布的高端，引力透镜放大的影响是显著的[19]；Stefano Schmidt 等人使用机器学习方法为双黑洞合并产生的引力波建立了一个时域模型，称为 mlgw[20]；Martti Raidal 等人在 LIGO 观测到的引

力波事件是由原始黑洞合并引起的假设下，证明了有可能满足目前对原始黑洞丰度的所有约束，并找到对数正态原始黑洞质量函数的可行参数范围[21]。因而，黑洞的独特性质及其强大的引力场为引力波的研究提供了重要的实验场。通过对黑洞周围引力波现象的观测与分析，科学家们得以验证广义相对论的预测并进一步探索宇宙的结构和演化。

2.5 黑洞观测

事件视界望远镜（Event Horizon Telescope, EHT）是一个分布于全球各地的超长基线天文望远镜阵列。EHT 通过将全球不同地点的多个射电望远镜联合起来，形成一个等效于地球直径尺度的巨大望远镜，从而观察黑洞附近的极端天文现象。2019 年，J. Lett 等人使用 EHT 捕捉到了距地球 5500 万光年的 Messier 87*（M87）黑洞图像，这是人类天文学史上首次采集到黑洞图像[22]。

目前，黑洞的观测数据主要来源于天文望远镜阵列等观测设备。由于黑洞强大的引力场导致光线发生弯曲，黑洞本身无法直接成像。因此，传统的天文观测方法（如观察星系或行星）无法用于黑洞的直接观测。我们只能通过间接方式观测黑洞周围物质的辐射信号和相对论效应，并结合数值模拟与数据重建等技术来推测黑洞的影像。例如，Högbom J. A.等人提出的 CLEAN 方法[23]，以及 Narayan 和 Nityananda 于 1986 年提出的正则化极大似然（RML）方法[24]。前者是一种反向建模方法，假设观测到的信号由多个点源或光源组合而成，并通过去卷积干涉仪的点扩散函数，从傅里叶变换的可见度数据中重建图像；而 RML 方法则为正向建模方法，在此基础上加入了正则化约束，除了确保图像与观测数据一致外，还强制图像满足一定的物理性质（如平滑性、紧凑性等），这一特性尤其适用于 EHT 这样需要处理大量复杂数据的场景。

与传统的直接呈现图像不同，黑洞图像的生成更依赖于物理模型、数学计算和模拟推断。传统天文图像通常通过光学、红外、射电等波段的观测获得，而黑洞图像则依赖更为复杂的数据采集方式，如多波段观测和干涉测量等。黑洞图像不仅包含传统的图像数据，还包括大量的光度、频率等物理信息[25]。这使得黑洞观测数据在处理上具有独特性，通常需要依赖相对论、量子力学等多重复杂理论进行分析。

此外，黑洞数据处理还面临数据量极大、对计算资源要求极高的挑战。以 2019 年 EHT 团队的观测为例，每个站点接收的天文信号以每秒 4GB 的速率进行数字化并记录

到硬盘上，仅一次观测的总数据量便达到 PB (10^6 GB) 级别。随后，团队采用高性能计算集群对原始数据进行校准、精化和分析[22]。随着数据量的不断增加，传统计算方法面临前所未有的挑战。黑洞图像的生成不仅需要巨大的数据量，还需要依赖复杂的物理模型，这对计算能力、存储容量和模型的精确度都提出了极高的要求。

与此同时，随着数据量的激增，机器学习方法为黑洞观测数据的处理提供了有效的解决方案。2023 年，Medeiros 等人提出了 PRIMO 算法，这是一种基于字典学习的成像算法。研究人员利用从一般相对论磁流体动力学 (GRMHD) 模拟中生成的大量合成图像作为训练集，训练了一个机器学习模型，并使用 2019 年 EHT 团队采集的黑洞数据重建了一幅改进的黑洞图像[26]。与旧图像相比，新图像在理论预期的基础上呈现出更高的一致性，有望进一步优化对 M87 发射环大小的估计，并基于此得出更为精确的黑洞质量评估。




图 2: (左) 2019 年 EHT 团队发布的首张黑洞图像;
(右) Medeiros 等人采用机器学习算法获得的改进图像。

3 深度学习技术介绍

深度学习（Deep Learning）作为一种强大的数据分析工具，在天文物理领域，尤其是黑洞研究中，发挥了重要作用。它能够处理和分析复杂的天文数据，提供新的洞察和预测能力。在黑洞研究中，深度学习技术主要应用于图像重建、时序信号分析、特征提取等任务。下面将详细介绍几种常用的深度学习技术，并阐述它们在黑洞研究中的潜在应用。

3.1 多层感知机（MLP）

多层感知机（MLP）是一种基础的前馈神经网络，它由多个层级的神经元组成，每个神经元通过加权连接与前一层和后一层的神经元相连。MLP 的输入层接受数据，经过若干个隐藏层的处理后，输出层给出预测结果。每个隐藏层通常使用非线性激活函数（如 ReLU、Sigmoid 或 Tanh）来引入非线性映射。

在黑洞研究中，MLP 可以用于各种回归和分类任务。例如，在黑洞图像的分类任务中，MLP 可以作为一个简单的分类器，将黑洞图像根据特定的物理特征（如黑洞质量、旋转速度等）分类。此外，MLP 还可以应用于特征选择和数据降维等任务，帮助提取图像或信号中的关键信息。

3.2 卷积神经网络（CNN）

卷积神经网络（CNN）是深度学习中最重要架构之一，广泛应用于图像处理领域。CNN 的核心思想是通过卷积层自动提取图像中的局部特征，并通过池化层减少特征图的尺寸，逐层提取越来越复杂的特征。CNN 通常由卷积层、池化层、全连接层和输出层组成。

在黑洞研究中，CNN 主要用于黑洞图像的重建和处理，尤其是在 Event Horizon Telescope（EHT）项目中，CNN 被用于黑洞事件视界的图像重建和图像去噪。例如，EHT 利用 CNN 处理来自多个望远镜的黑洞图像数据，以增强图像质量并重建黑洞周围的细节结构。

3.3 长短期记忆网络（LSTM）

长短期记忆网络（LSTM）是一种改进的递归神经网络（RNN），其设计目的是解决传统 RNN 在处理长时间序列时容易出现梯度消失或梯度爆炸的问题。LSTM 通过引入三个门控机制（输入门、遗忘门和输出门）来控制信息在时间步之间的传递，从而可以有效地捕捉长期依赖关系。

LSTM 非常适合处理时间序列数据。在黑洞研究中，LSTM 可以用于处理黑洞周围的时变信号，特别是来自黑洞附近物质的辐射信号，如 X 射线、伽玛射线等。通过学习这些时序信号，LSTM 能够识别黑洞的活动模式，如黑洞合并、吸积盘变化等。

3.4 双向长短期记忆网络（Bi-LSTM）

双向长短期记忆网络（Bi-LSTM）是在 LSTM 的基础上进行改进的一种模型。与标准的 LSTM 只能利用前向序列的信息不同，Bi-LSTM 通过在同一时间步同时使用前向和后向两个 LSTM 网络，使得模型能够同时捕捉序列的前后依赖关系。这使得 Bi-LSTM 在处理具有双向时间依赖性的数据时，比传统的 LSTM 更为强大。

在黑洞研究中，Bi-LSTM 能够更好地处理那些有前后关联的时序数据。例如，在分析双黑洞合并事件时，信号可能会有前后关系，Bi-LSTM 能够同时考虑事件发生前后的所有信息，从而提高对信号的理解和预测能力。

3.5 时序卷积网络（TCN）

时序卷积网络（TCN）是一种基于卷积神经网络的模型，专门用于处理时间序列数据。与传统的递归神经网络（如 LSTM 和 GRU）不同，TCN 使用卷积层代替递归结构来捕捉时间序列中的长程依赖。通过扩展卷积核和使用因果卷积（确保预测值仅依赖于历史信息），TCN 能够有效地建模时间序列中的长期依赖关系。

对于黑洞研究中的时序数据，TCN 可以被用于信号处理和事件预测。例如，TCN 可以用于分析黑洞附近的喷流或吸积盘的变化，帮助我们理解这些现象的时间演化过程。

3.6 Transformer

Transformer 是一种基于自注意力机制（Self-Attention）和前馈神经网络（Feed-

Forward Network) 构建的深度学习架构, 它在 2017 年由 Vaswani 等人提出, 迅速成为处理序列数据, 尤其是自然语言处理任务的主流方法。Transformer 的核心优势在于其完全依赖自注意力机制而无需任何递归 (如 LSTM) 或卷积 (如 CNN) 结构, 从而能够在并行计算的基础上捕捉全局依赖, 处理长程信息, 并显著提高训练效率。

Transformer 模型的设计主要基于编码器 (Encoder) 和解码器 (Decoder) 的结构。每个编码器层和解码器层包含多个相同的子层, 核心操作就是 **自注意力机制** 和 **前馈神经网络**, 同时加上 **位置编码** 来补充序列数据的顺序信息。

3.6.1 基本结构

Transformer 模型的编码器和解码器都由多个相同的层堆叠而成。每个编码器层包含两个子层: 多头自注意力机制 和 前馈神经网络。每个解码器层除了这两个部分外, 还包括 编码器-解码器注意力机制, 用于将编码器的输出与解码器当前状态结合, 生成目标输出。每个子层之间通过 残差连接 和 层归一化 (Layer Normalization) 来加速训练和稳定性。

Transformer 中的每一层都包括自注意力计算、前馈神经网络以及位置编码的作用。最终, 编码器生成的表示通过解码器进行处理, 生成模型的输出序列。通过这种完全基于自注意力的结构, Transformer 可以有效地处理长序列数据, 并且能够并行计算, 显著提高训练效率。

3.6.2 自注意力机制 (Self-Attention)

自注意力机制是 Transformer 的核心技术之一, 其目标是让模型在处理某一位置的信息时能够考虑序列中所有其他位置的信息。这一机制通过计算输入序列中每个元素的 **查询 (Query)** 和 **键 (Key)** 之间的相似度, 来动态调整每个元素对其他元素的关注程度。

对于输入序列 $X = [x_1, x_2, \dots, x_n]$, 我们首先通过学习得到三个权重矩阵 W_q, W_k, W_v 将输入映射到查询、键和值向量空间:

$$Q = XW_q, K = XW_k, V = XW_v$$

其中, W_q, W_k, W_v 是学习的参数矩阵, 分别将输入映射到查询、键和值空间。每个向

量的维度是 d ，通常是 d_k 为查询和键的维度， d_v 为值的维度。

接下来，通过计算查询向量和键向量的点积来衡量它们的相似度，得到一个表示每个位置对其他位置注意力得分的矩阵：

$$Attention(Q, K) = \frac{QK^T}{\sqrt{d_k}}$$

这里， QK^T 是查询和键的点积， $\sqrt{d_k}$ 是对点积结果进行缩放的因子，用于稳定训练。

通过 `softmax` 函数将这些得分归一化，得到注意力权重：

$$Attention\,Weights = softmax(\frac{QK^T}{\sqrt{d_k}})$$

这些注意力权重会根据每个位置对其他位置的关注程度来调整每个位置的表示。

然后，计算加权求和值向量，得到最终的输出：

$$Output = Attention * Weights * V$$

这样，模型就得到了每个输入向量的加权表示，其中的每个加权值反映了序列中其他元素对该位置的影响。

3.6.3 多头自注意力（Multi-Head Attention）

多头自注意力机制通过并行使用多个注意力头来增强模型的学习能力。每个头使用不同的查询、键和值矩阵进行独立的自注意力计算，从而学习输入序列的不同方面的表示。最终，将每个头的输出连接起来，并通过一个线性变换得到最终的输出表示：

$$MultiHead(Q, K, V) = Concat(head_1, head_2, \dots, head_h)W_o$$

其中， h 表示头的数量， $head_i = Attention(QW_q^{(i)}, KW_k^{(i)}, VW_v^{(i)})$ 是第 i 个头的输出。 W_o 是学习的线性变换矩阵。通过多头注意力，模型能够在不同的子空间中独立学习不同的注意力模式，从而提高了模型的表达能力。

3.6.4 位置编码（Positional Encoding）

由于 Transformer 没有内在的序列处理机制，因此需要通过位置编码来为模型提供

序列的位置信息。位置编码是一个与输入序列长度相同的向量序列，通常通过正弦和余弦函数生成。对于位置 pos 和维度 i ，位置编码可以表示为：

$$PE_{(pos,2i)} = \sin\left(\frac{pos}{1000^{\frac{2i}{d}}}\right), \quad PE_{(pos,2i+1)} = \cos\left(\frac{pos}{1000^{\frac{2i}{d}}}\right)$$

这里， d 是输入向量的维度， pos 是序列的位置， i 是位置编码的维度索引。位置编码通过添加到输入嵌入（Embedding）中，帮助 Transformer 学习到序列中元素的相对或绝对位置。

3.6.5 前馈神经网络（Feed-Forward Networks）

Transformer 中的每个编码器层和解码器层都包含一个前馈神经网络（Feed-Forward Network, FFN）。FFN 由两个全连接层组成，通常包含 ReLU 激活函数。给定输入向量 x ，前馈网络的计算如下：

$$FFN(x) = \max(0, xW_1 + b_1)W_2 + b_2$$

其中， W_1, W_2 是全连接层的权重矩阵， b_1, b_2 是偏置项。前馈神经网络的作用是对每个位置的表示进行非线性转换，从而增强模型的表达能力。

4 引力波分析

4.1 引言

引力波的首次直接探测（GW150914 事件）标志着天文学和物理学的重大突破，为研究黑洞、宇宙起源和时空结构提供了全新的视角。然而，引力波信号的探测面临极大的挑战。黑洞并合事件产生的引力波信号往往被各种噪声所淹没，包括探测器的本底噪声、地面振动干扰和设备伪信号等。这些噪声的存在显著降低了信号的信噪比，影响了科学数据的精确性与可靠性。因此，开发高效的去噪和检测技术，对于解锁引力波观测的科学潜力具有关键作用。

在过去几年中，针对引力波信号的去噪与检测问题，科学家们提出了多种方法。从传统的匹配滤波和小波变换技术，到基于机器学习的深度神经网络方法，每种技术在不同场景下均展现出独特的优势。例如，匹配滤波在已知信号模板下表现优异，但对未知信号的鲁棒性不足；而深度学习方法则能够通过数据驱动的方式实现高效的信号分类和去噪，但其泛化能力和可解释性仍面临挑战。尽管如此，相关技术的快速发展正在不断提升引力波信号处理的精度，为研究复杂天体物理现象提供了坚实的技术基础。

本部分旨在系统梳理黑洞引力波信号去噪与检测的研究进展，总结现有去噪和检测方法，包括经典信号处理技术和基于机器学习的现代算法。

4.2 研究进展

4.2.1 传统方法

引力波信号去噪技术是提升检测精度和提高观测灵敏度的核心领域，其发展历程中积累了多种基于经典信号处理理论的技术方法。这些传统方法为早期引力波探测实验提供了理论支撑，并在 LIGO 和 Virgo 等干涉仪的观测任务中发挥了重要作用。

匹配滤波（Matched Filtering）是最早被引入引力波信号检测的核心技术之一，至今仍是处理已知模板信号的标准方法。该方法通过计算探测数据与理论模板的互相关函数，寻找信号的最佳匹配程度，从而实现高效提取。匹配滤波在已知模板信号（如黑洞并合产生的啁啾信号）下表现尤为出色，其对目标信号与噪声统计特性之间的匹配度敏感，能够最大化信噪比（SNR）。例如，Benjamin J. Owen 等人（1999）[27]对紧密二元

体引力波的匹配滤波搜索进行了深入分析。作者们通过精确估算用于一阶段匹配滤波搜索的模板数量、计算能力及存储需求，为即将投入使用的干涉仪（如 LIGO 和 VIRGO）提供了重要的基准数据。然而，匹配滤波在实际应用中面临显著的局限性。首先，该方法高度依赖于预定义的模板库，而模板库的构建需要对引力波源参数进行广泛采样，这不仅增加了计算复杂度，还限制了其在未知信号处理中的适用性。此外，模板匹配对于强背景噪声条件下的检测灵敏度可能下降，尤其是在非高斯噪声场景中更为显著。

为了克服匹配滤波的不足，**小波变换 (Wavelet Transform)** 被广泛应用于引力波信号的时频分析与去噪中。小波变换通过多分辨率分析技术，将信号分解为不同频率和时间分量，使得短时强非平稳信号的特征能够在时频域中得到清晰呈现。这一特点特别适用于处理黑洞并合信号以及干涉仪探测数据中的瞬态噪声。连续小波变换 (CWT) 能够以较高分辨率生成信号的时频表示，进而捕捉不同尺度的噪声特性；而离散小波变换 (DWT) 则凭借其计算效率，在大规模观测数据处理中具有优势。例如，A Virtuoso 等人 (2024) [28] 提出了一种名为波形 Q-变换 (wavelet Q-transform) 的方法，不仅解决了传统小波变换在可逆性和计算效率方面的局限性，还通过引入 Morlet 小波的参数化形式，使得信号的重构和噪声过滤更加高效。然而，小波变换的性能在一定程度上依赖于小波基函数的选择，不同小波基可能对特定类型信号或噪声表现出较大的差异，这需要结合具体应用场景进行优化。

除了匹配滤波与小波变换，其他传统信号处理方法也被广泛用于引力波数据分析中。**自适应滤波 (Adaptive Filtering)** 是应对动态噪声的重要工具之一，其通过实时调整滤波器参数，能够抑制低频噪声和地震干扰等非平稳噪声源。自适应滤波尤其适合在未知或变化噪声环境中工作。例如，Chassande-Mottin 等人 (2001) [29] 提出了一种基于最小均方 (LMS) 自适应线性预测的去噪算法，针对由长周期正弦干扰和短期振铃噪声构成的复杂噪声环境。该方法的优点在于无需对噪声特性进行精确建模，而是通过信号的自相关时间来区分信号与噪声；Torres-Forné 等人 (2016) [30] 提出了一种基于字典学习的去噪方法，旨在提高低信噪比引力波事件的检测能力。该方法通过构建包含二元黑洞合并和旋转核心崩溃波形的字典，利用稀疏表示模型有效地分离信号与噪声。但其性能在高动态变化场景下可能受到参数调优效率的限制。

此外，**卡尔曼滤波 (Kalman Filtering)** 在低频噪声的抑制中表现出色。通过结合动

态系统模型与噪声统计信息，卡尔曼滤波能够对信号进行递归估计，其在地面干涉仪的噪声补偿中展现了显著效果。然而，这一方法对系统模型的准确性依赖较高，在复杂多源噪声场景下的适用性仍有待进一步研究。

传统的信号去噪方法如匹配滤波和小波变换虽然在早期取得了重要进展，但在应对复杂非高斯噪声和非模板信号时表现出明显局限性。近年来，机器学习方法以其在非线性建模和模式识别中的卓越性能，为引力波信号的去噪与检测开辟了全新的研究路径，逐渐成为该领域的研究热点。

4.2.2 CNN

深度学习模型，尤其是**卷积神经网络（CNN）**，在引力波信号去噪与检测中表现出强大的能力。CNN 通过自动提取时空域或时频域信号的局部特征，实现信号与噪声的高效分离。典型的应用包括利用短时傅里叶变换（STFT）或连续小波变换（CWT）将时域信号映射到时频域，从而生成输入 CNN 的时频图像。CNN 模型能够通过其卷积核学习到关键的信号模式，在干扰严重的环境中仍然保持对引力波信号的高灵敏度检测。例如，Wei Wei 等人（2020）[31]提出了一种基于 CNN 的去噪方法，旨在解决传统去噪技术在处理长时间引力波信号时的局限性。研究中采用了 WaveNet 架构，利用扩张卷积技术来捕捉长时间相关性，显著提高了去噪的准确性，通过在模拟和真实的 LIGO 噪声下进行训练与测试，模型展示了卓越的去噪能力，输出信号与数值相对论模板间的重叠度高达 0.99；Rich Ormiston 等人（2020）[32]提出的 DeepClean 算法基于卷积神经网络（CNN），通过对辅助信号的深入分析，有效地降低了因环境和仪器噪声引起的干扰，在训练过程中，算法采用加权幅度谱密度和均方误差作为损失函数，以优化网络参数并提高噪声去除的准确性。该方法在处理线性和非线性耦合时表现出色；Morales 等人（2021）[33]采用 CNN 对紧凑双星并合（CBC）引力波信号进行检测，利用 Morlet 小波变换，通过将真实 LIGO 探测器的单干涉仪数据转化为时频图像，显著提高了信号的可识别性。研究中，作者提出了一种重采样白盒方法，旨在深入理解 CNN 在处理引力波数据分析中的不确定性；Lopac 等人（2021）[34]提出了一种基于 Cohen 类时间频率表示的 CNN 方法，旨在提高非平稳引力波信号在复杂噪声环境中的检测性能。该研究采用了三种先进的 CNN 架构（ResNet-101、Xception 和 EfficientNet），通过引入 12 种不同的时间频率表示，分类准确率高达 97.10%，显著提升了信号分类的准确性；Zhang

等人 (2022) [35] 提出了一种基于傅里叶变换和 CNN 的引力波信号识别模型，创新性地 将引力波的时域信号转换为二维频域信号图，以实现更高效的特征识别。在多次实验中， 模型在不同信噪比条件下的平均识别准确率比 ResNet101 高出约 4%；Murali 等人 (2022) [36] 提出了一种基于卷积神经网络 (CNN) 的自编码器架构，能够有效地从原始引力波 数据中提取信号并去除噪声。该方法通过短时傅里叶变换 (STFT) 将一维时间序列数据 转换为二维时频域表示，CNN 则学习到信号与噪声之间的非线性映射。在实际应用中， 该模型成功恢复了 GW150914 事件的信号，在 Hanford 探测器上实现了 86% 的重叠率， 而在 Livingston 探测器上则为 80%。此外，该方法的单个探测器虚假警报概率 (FAP) 低至 0.01% 和 0.2%；Bacon 等人 (2023) [37] 提出了一种基于卷积自编码器的去噪算法， 专门针对双黑洞合并引力波信号，作者在真实的 LIGO O1 和 O2 数据集上进行了评估， 结果表明，当信噪比 (SNR) 达到 8 时，去噪后的信号与注入信号的波形重叠度 (Overlap) 平均达到 0.8 以上；Reissel 等人 (2024) [38] 提出了一种创新性的方法，称为 Coherence DeepClean (CDC)，该方法集成了协同监测与 CNN 去噪算法，该研究利用协同监测工 具 (CohMon) 识别与引力波信号相关的辅助通道，通过计算信号间的相干性，筛选出 高相干性的通道进行噪声去除，研究结果表明，经过 CDC 处理后，二元中子星的探测 范围提高了 1.4%，这相当于敏感体积的 4.3% 增长。尽管如此，CNN 的性能依赖于训练 数据的分布和规模，其泛化能力在处理实际观测中的复杂噪声场景时可能受到限制。

4.2.3 CNN + 其余模型结构

因此，许多研究逐步超越了单纯依赖卷积神经网络 (CNN) 进行特征提取的限制， 探索将其他先进的时间序列建模方法与 CNN 相结合，从而实现模型结构的进一步创新。 例如，长短期记忆网络 (LSTM) 因其对长时间依赖关系的建模能力被广泛引入，引力 波信号处理中的许多工作尝试通过融合 CNN 与 LSTM，综合发挥卷积层提取局部空间 特征和 LSTM 捕捉时间依赖性的优势。与此同时，时序卷积网络 (Temporal Convolutional Network, TCN) 凭借扩展卷积 (Dilated Convolution) 的全局感受野设计， 展示了在处理长时间序列信号中的优越性，与 CNN 结合后表现出更高的信号与噪声分 离能力。此外，双向长短期记忆网络 (Bi-LSTM) 通过同时建模前后序列依赖，为信号 去噪任务提供了更全面的特征捕捉能力。

在这些传统序列模型的基础上，Transformer 和 Self-Attention 等基于注意力机制

的模型引入了全局建模的新范式。Transformer 的模块化架构在捕捉全局时间序列关系的同时，通过**自注意力机制（Self-Attention）**重点关注信号中的关键特征，避免了传统 RNN 模型中的梯度消失问题。这些方法与卷积网络或其他序列建模方法相结合，不仅提高了去噪性能，还为复杂噪声场景下的信号检测提供了更加鲁棒的解决方案。这些模型结构上的创新为引力波信号去噪与检测的研究注入了新的活力。

例如：Nigam 等人（2020）[39]提出了一种基于卷积神经网络（CNN）和长短期记忆网络（RNN-LSTM）的混合方法，用于分类低信噪比（SNR）引力波数据中的瞬态信号，研究团队生成了包含八种不同类型瞬态信号的数据集，信号经过白化处理以减少低频噪声的影响；Chatterjee 等人（2021）[40]提出了一种基于卷积神经网络（CNN）和双向长短期记忆网络（Bi-LSTM）的去噪自编码器模型，用于从复杂的噪声背景中提取二元黑洞（BBH）引力波信号。该模型的输入为经过标准化的引力波信号，长度为 0.25 秒，采样率为 2048 Hz。实验结果表明，在信噪比（SNR）大于 6 的条件下，模型能够实现与纯数值模板的重叠度超过 0.95。此外，在处理 LIGO-Virgo 的十个实际探测事件时，提取的波形与对应模板的重叠度均达到 ≥ 0.97 ，显示出良好的准确性和鲁棒性；Lin 等人（2021）[41]提出了一种新型的贝叶斯神经网络模型，该模型通过四个卷积块提取输入信号的特征，并通过贝叶斯卷积来量化预测的不确定性。LSTM 部分则负责捕捉信号的时间序列特性，确保早期信号（如引力波的引发阶段）也能够被有效识别。研究结果表明，当信噪比（SNR）超过 7 时，该模型检测到 90% 的引力波事件，且在 SNR 超过 8.5 时，检测率达到了 100%；He Wang 等人（2022）[42]提出的 WaveFormer 模，为引力波信号的去噪和检测提供了一种新的思路。该模型结合了卷积神经网络（CNN）和 Transformer 架构，通过层级特征提取有效地减少了引力波观测数据中的噪声，在相位恢复方面，WaveFormer 的相位重叠度超过了 0.99，误差仅为 1%。对于幅度恢复，其均方根误差（RMSE）小于 0.53，且相对幅度恢复误差约为 7%；Tianyu Zhao 等人（2023）[43]提出了一种基于卷积神经网络（CNN）和自注意力机制的深度学习模型，该模型在复杂的高斯噪声背景下表现出了优异的性能。在信噪比为 50 的情况下，模型的引力波信号检测率超过 99%，假警报率仅为 1%；Chatterjee 等人（2024）[44]提出的 AWaRe 模型，结合了卷积神经网络（CNN）和长短期记忆网络（LSTM），实现了对引力波信号的高效重构。该模型在处理黑洞合并的模拟信号时，重构结果与原始波形之间的重叠度（Overlap）高达 0.98，显示出卓越的性能。

尽管机器学习方法在引力波信号去噪与检测中取得了显著进展，但其仍面临一些亟待解决的问题。首先，机器学习模型的训练过程高度依赖于高质量的大规模标注数据，而这些数据的获取和标注在实际中具有很高的成本。其次，模型的泛化能力在应对复杂的实际观测数据（如 LIGO 的非高斯噪声和瞬态噪声）时存在一定的局限性。此外，模型的黑箱性质使得对去噪过程和信号特征提取的物理解释不够透明，这在科学研究中可能导致对关键物理信号的遗漏或误判。

4.3 未来展望

未来的研究方向可以集中在以下几个方面：其一，探索小样本学习（Few-shot Learning）或迁移学习（Transfer Learning）技术，以减轻数据需求对模型性能的限制；其二，开发可解释性更强的模型架构，结合物理先验知识提升信号分析的透明性；其三，进一步挖掘传统信号处理方法与机器学习的融合潜力，构建适用于复杂噪声场景的混合模型。这些努力将有助于推动引力波信号去噪与检测技术的进一步发展，为未来的多信使天文学观测奠定更加坚实的基础。

5 射电波分析

5.1 引言

在天文学领域，对远距离天体的观测，射电望远镜起着极为关键的作用。它作为专门用于观测天体射电波段的设备，为我们深入探索宇宙奥秘提供了重要手段。然而，射电望远镜在合成图像时，不可避免地会受到一些因素的干扰，从而产生噪音。其中，随机仪器噪声是仪器本身在运行过程中产生的干扰因素，而孔径合成技术虽然有助于提高射电望远镜的观测能力，但也会带来旁瓣伪影效应，这两种因素共同作用，导致射电望远镜合成的图像往往伴随着噪音。这些噪音严重影响了图像的清晰度，进而对天体的准确识别造成了阻碍，因此需要对合成后的图像去噪。本节以射电波图像的去噪与重建为例，讲述了深度学习在射电波分析领域的应用。

5.2 研究进展

传统去噪方法（如高斯滤波、小波变换和非局部均值算法）虽能缓解简单噪声，但对复杂天文场景中微弱信号与噪声的分离效果有限，尤其在处理黑洞射电数据时，难以平衡细节保留与噪声抑制的冲突。[45] [46]这一局限促使研究者转向数据驱动的机器学习方法，以突破传统算法的物理建模瓶颈。很长一段时间内，图像去噪工作主要集中在传统的图像处理技术上，但这些方法在处理复杂的射电天文图像时效果有限。

2021 年，射电天文图像去噪领域迎来两项突破性进展。C Gheller 等人提出了使用卷积去噪自编码器（CDA），首次将深度学习的非线性表征能力引入射电图像处理。[47]该模型通过多层卷积与反卷积结构构建对称编码-解码网络，利用跳跃连接融合不同尺度的特征，有效抑制旁瓣伪影的同时增强了对弥散射电源的识别能力。实验表明，CDA 在模拟的射电星系团数据集中，信噪比（SNR）提升达 40%，且对微弱射电喷流的还原精度显著优于传统方法。值得注意的是，其设计虽未针对黑洞数据优化，但因黑洞图像的稀疏性与复杂噪声分布特征与射电星系团相似，CDA 成为后续黑洞图像重建的关键预处理模块。

同年，Johanna S. Karras 等人探索了通用卷积神经网络（CNN）的迁移学习潜力。他们利用自然图像与合成射电数据联合训练的模型，成功复原了模拟黑洞阴影的干涉测

量数据。该研究揭示了，通过引入物理约束（如空间频率域的稀疏性先验），通用模型可自适应学习天文图像特有的统计规律[48]。

未来，射电波图像去噪技术有望借助多模态联合数据、小样本学习、实时处理与边缘计算等先进手段，显著提高去噪效果与精度。通过融合不同来源的数据，能够更全面地捕捉图像的多维信息；而小样本学习则为数据稀缺的场景提供了新的解决方案。同时，实时处理和边缘计算的结合使得图像去噪能够在数据产生的源头快速进行，提高处理效率。此外，从模型的可解释性入手，开展系统的理论分析，能够进一步提升去噪模型的透明度和可信度，为该领域的长远发展奠定坚实基础。

6 黑洞参数估计

6.1 引言

黑洞参数估计是引力波天文学中的重要课题。它通过对引力波信号或其经过处理得到的黑洞图像进行分析，以提取黑洞系统的物理参数，如质量、自旋、轨道倾角等。该领域的研究不仅加深了人们对黑洞性质的理解，还为测试广义相对论在强引力场中的有效性提供了重要途径。常用的黑洞参数估计方法通常需要先构建波形模板模型，并结合先进的信号处理与数据分析技术，如匹配滤波、贝叶斯参数估计等，以从观测数据中提取出引力波信号的特征，最终借助物理和天文学模型对源的物理参数进行估计。通过分析这些参数，研究人员可以揭示黑洞的物理特性、揭示天体之间的相互作用机制，并为验证引力理论的准确性以及理解宇宙中的极端天文现象提供重要依据。

6.2 研究进展

传统的参数估计方法，如匹配滤波和贝叶斯参数估计等，适用于处理短时且高信噪比的信号。然而，在面对复杂且低信噪比的信号（如极端质量比螺旋进动（EMRI）信号）时，却有着显著的局限性。首先，传统方法依赖于精确的波形模板拟合，这通常需要消耗大量计算资源，特别是在高维参数空间中，计算量极为庞大。其次，传统方法在处理复杂信号时的适应性较差，容易受到噪声干扰，导致错误的参数估计。再者，对于像 EMRI 这样复杂的低频信号，受自力效应、时空涡旋和轨道不稳定性等因素的影响，波形难以准确预测，从而使得模板的构建变得异常困难。这些问题共同限制了传统方法在复杂系统参数估计中的应用表现。

近年来，随着深度学习技术的发展，尤其是卷积神经网络（CNN）、长短时记忆网络（LSTM）等模型在天文学领域的应用，越来越多的深度学习方法被引入到引力波数据分析中。与传统方法相比，深度学习通过自动化的特征提取和模式识别能力，能够从海量数据中高效地学习信号的潜在特征，克服了传统方法的模板依赖性和计算瓶颈。因此，深度学习在处理复杂、低信噪比和噪声较大的引力波信号时，展现出了更强的优势，并具有广阔的应用前景。

例如，[49]用深度学习改进了传统的基于流的生成模型[50][51]，以高效地从 LVK(LIGO-

Virgo-Kagra) 数据中提取并估计引力波信号的参数。进一步的研究还采用了卷积神经网络 (CNN) 进行黑洞参数的预测。例如, Joshua Yao-Yu Lin 等人[52]使用标准的深度残差网络架构 ResNet-18, 从合成黑洞图像中提取关键参数, 分析神经网络特征图以识别低亮度螺旋臂特征。[53][54]则针对任务构建了 CNN 模型, 以此检测极端质量比螺旋进动 (EMRI) 信号, 展示了在大规模数据端到端训练的基础上, CNN 在复杂信号环境中的突出表现。[55]使用 VGG-Net 模型[56]从天体图像中推断参数, 展现了卷积网络的通用模型在引力波参数估计领域中优秀的泛化性能。此外, 还有研究引入了注意力机制[57], 通过增强模型对重要特征的关注来提升对复杂信号的识别能力。例如, [58]的工作利用统一的多级自注意力模型对高斯噪声中的合成 GW 信号进行识别, 达到了超过 99% 的准确率, 且具有良好的可解释性和泛化能力。

深度学习的引入显著提升了传统方法在复杂信号处理中的表现, 特别是在黑洞参数估计和引力波信号分析领域, 展现了其强大的适应性、准确性和高效性。与传统方法依赖波形模板和精细参数拟合不同, 深度学习通过自动化特征提取和模式识别能力, 能够应对高维、低信噪比和噪声较大的信号环境。特别是在处理如 EMRI 等复杂的低频信号时, 深度学习的灵活性和容错性使其成为解决这些问题的有力工具。此外, 深度学习模型的训练不再依赖于精确的模板拟合, 这减少了计算量并有效突破了传统方法的瓶颈。随着相关技术的不断发展, 深度学习在引力波天文学和黑洞物理学中的潜力将进一步得到挖掘。

6.3 未来展望

展望未来, 深度学习有望为引力波天文学提供更加精确、可靠的分析工具, 尤其是在面对更复杂的信号时。在信号源方面, 深度学习能够更好地处理来自不同物理过程 (如黑洞合并、脉冲星碰撞等) 的多样化信号。此外, 随着硬件技术的进步和计算能力的提升, 深度学习模型将在大规模数据处理和实时分析中发挥越来越重要的作用。为了进一步推动这一领域的发展, 未来的研究可以集中于提高深度学习模型的可解释性和透明度, 使得科学家能够更好地理解模型的决策过程和参数估计结果。同时, 结合物理学的先验知识和深度学习算法, 将为研究人员提供更加准确和具有物理意义的结果, 推动引力波探测器的精度和灵敏度提升。深度学习在引力波数据分析中的广泛应用, 将为我们揭示宇宙中更加深奥和复杂的物理现象, 进一步推动天文学和物理学的发展。

7 大模型方案

7.1 已有研究总结

为给出对黑洞领域研究的一个具体方案，需要根据我们对 ML、DL 的理解总结前人已经完成的研究，将文章中提到的机器学习、深度学习方法与对应的黑洞研究领域整理成表格大致如下：

表 3 文献内容总结

算法	研究领域	具体应用
多层感知机 (MLP)	黑洞图像分类、特征选择、数据降维	用于黑洞图像的分类任务，根据黑洞质量、旋转速度等物理特征进行分类；特征选择和数据降维，帮助提取图像或信号中的关键信息。
卷积神经网络 (CNN)	黑洞图像重建、去噪、引力波信号去噪与检测	用于黑洞事件视界的图像重建和去噪（如 EHT 项目）；处理引力波信号，通过时频图像提取特征，实现信号与噪声的分离。
长短期记忆网络 (LSTM)	黑洞时序信号分析、引力波信号去噪与检测	处理黑洞周围的时变信号（如 X 射线、伽玛射线），识别黑洞活动模式（如黑洞合并、吸积盘变化）；与 CNN 结合，捕捉引力波信号的时间依赖性。
双向长短期记忆网络 (Bi-LSTM)	黑洞时序信号分析、引力波信号去噪与检测	处理具有前后关联的时序数据（如双黑洞合并事件），同时考虑事件发生前后的信息，提高信号理解和预测能力。
时序卷积网络 (TCN)	黑洞时序信号分析、引力波信号去噪与检测	用于分析黑洞附近的喷流或吸积盘的变化，捕捉时间序列中的长期依赖关系；与 CNN 结合，提高信号与噪声的分离能力。
Transformer	引力波信号去噪与检测、黑洞时序信号分析	通过自注意力机制捕捉全局时间序列关系，处理引力波信号中的关键特征；与 CNN 结合，提高去噪性能和信号检测的鲁棒性。
卷积去噪自编码器 (CDA)	黑洞图像去噪	用于射电天文图像的去噪，去除复杂图像中的噪声，识别和提取微弱的射电源。
主成分分析 (PCA)	黑洞图像重建	用于黑洞观测数据的图像重建，结合字典学习技术，提高图像分辨率和清晰度。
深度残差网络 (ResNet)	黑洞图像特征提取	从合成的黑洞图像中提取关键参数，识别低亮度螺旋臂特征，可能与黑洞吸积盘和喷流中的湍流特征有关。

U-Net	黑洞环境模拟	用于预测黑洞吸积流的时间演化，模拟黑洞吸积流的时空演化过程。
贝叶斯深度学习 (DPNNet)	吸积盘预测、黑洞参数估计	用于从原行星盘的行星间隙预测行星质量，量化预测不确定性；改进传统参数估计方法，处理复杂、低信噪比的引力波信号。
回声状态网络 (ESN)	吸积盘预测	用于预测原恒星盘演化过程中的质量吸积率，捕捉系统的非线性动力学特征。
生成对抗网络 (GAN)	黑洞图像重建、引力波信号去噪	用于生成高保真的黑洞图像和引力波信号数据，优化成像算法和去噪效果。
自编码器 (Autoencoder)	引力波信号去噪	用于从原始引力波数据中提取信号并去除噪声，恢复低信噪比信号。
贝叶斯神经网络	引力波信号检测与参数估计	用于检测引力波信号并量化预测的不确定性，结合物理先验知识提升信号分析的透明性。
注意力机制 (Self-Attention)	引力波信号去噪与检测、黑洞参数估计	通过增强模型对重要特征的关注，提升对复杂引力波信号的识别能力；用于黑洞参数估计，提高模型的准确性和可解释性。

根据上表主要黑洞研究和其应用的技术可以将使用到的模型总结为以下四类：

- **时序信号分析：**LSTM、Bi-LSTM、TCN、Transformer 等用于处理黑洞周围的时变信号和引力波信号。
- **信号去噪与检测：**CNN、LSTM、Transformer、自编码器等用于引力波信号的去噪与检测。
- **图像处理：**CNN、CDA、PCA、Res-Net、U-Net、GAN 等用于黑洞图像的去噪、重建和特征提取。
- **参数估计与预测：**贝叶斯深度学习、DPN-Net、ESN、贝叶斯神经网络等用于黑洞参数估计和吸积盘预测。

本文主要对射电波信号进行图像处理方面提出深度学习技术的创新应用方案，具体见下节所述。

7.2 扩散模型

考虑到有很大一部分的研究都将深度学习模型用于信号降噪方面，尤其是图像降噪领域我们认为可以使用 Diffusion 模型（扩散模型）[59]用于图像去噪还原。Diffusion 模型是一类生成模型，通过深度学习神经网络学习（纯）噪声图像的去噪过程，近年来在

图像生成、去噪、超分辨率等任务中表现出色，尤其在 AI 绘画领域应用广泛。

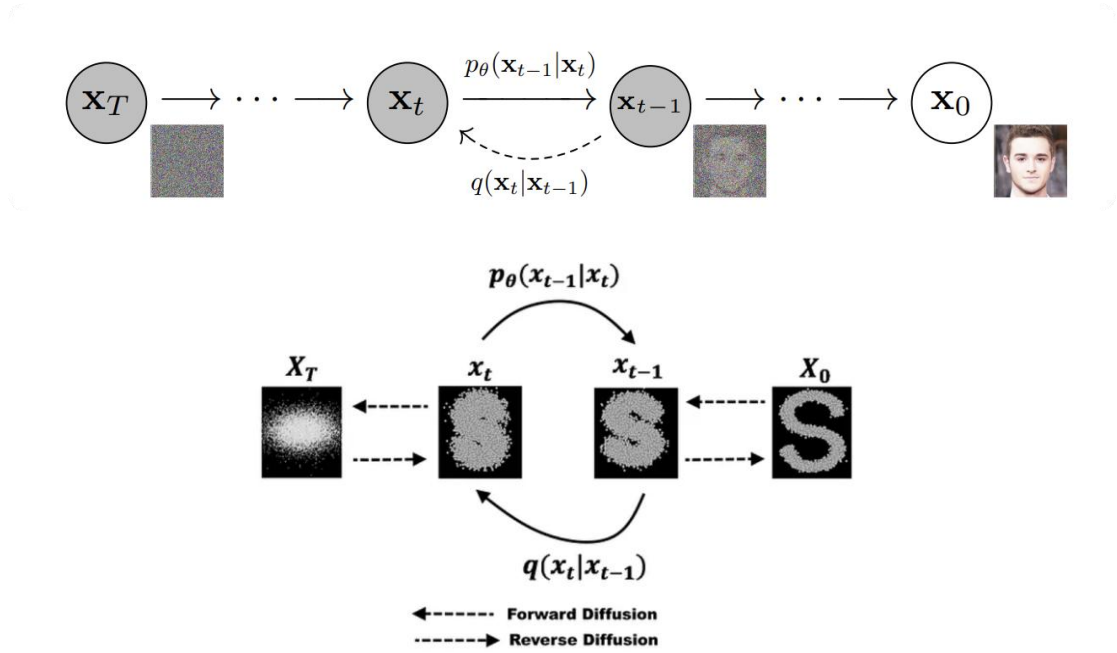


图 3： 扩散模型（图片来源 Medium 网站）[59]

而黑洞图像（如事件视界望远镜 EHT 拍摄的图像）的获取通常受到噪声和低分辨率的限制，尤其是在射电波段观测中，噪声和旁瓣伪影会严重影响图像质量。而针对噪声和低分辨率的限制，Diffusion 模型可以针对性地解决这两个问题，在一定程度上能超越已有的 CNN、GAN 等方式：

- **去噪：**通过学习逐步去噪的过程，从噪声数据中恢复出清晰的黑洞图像，有效处理复杂的噪声分布，尤其是非高斯噪声。
- **超分辨率重建：**从低分辨率观测数据中生成高分辨率的黑洞图像，帮助科学家更清晰地观察黑洞的细节结构（如吸积盘、喷流等）。

7.2.1 模型基础结构

Diffusion 模型的主要特点是生成质量高、训练稳定，并且能够生成多样化的样本。模型的核心思想是通过模拟物理中的扩散过程，逐步将数据从噪声分布转换到目标分布，其建模数据分布的过程可以概括为以下两个步骤：

- **前向过程 (Forward Process)：**将数据逐步添加噪声，最终将数据转化为高斯噪声。这一过程可以看作是一个马尔可夫链，每一步都向数据添加少量噪声。
- **反向过程 (Reverse Process)：**通过学习如噪声的添加次数减少何逐步去除噪声，将高斯噪声转换回原始数据分布。这一过程是通过神经网络来建模的。

7.2.2 模型调整

为了使 Diffusion 模型更好的达到目标效果，需要针对天文学方面的应用对模型的结构和数据进行如下调整：

- **模型结构：**减少噪声添加的次数，目标变为从低噪声数据中还原图像；
- **模型数据：**原始数据使用模拟的黑洞图像或真实射电望远镜观测数据，人为地对这些数据添加噪声和旁瓣伪影作为模型训练数据；

在模型结构设计上，针对黑洞观测数据中天然蕴含复杂物理噪声的特性，可以优化传统扩散模型的前向过程机制，减少噪声添加的次数，不同于常规扩散模型依赖长链马尔可夫过程逐步添加噪声，基于真实观测场景中不存在绝对"纯净"数据的物理事实，通过动态调整噪声注入的迭代次数与强度分布，显著缩短了马氏链长度。这种物理启发的结构改进不仅大幅提升了模型训练效率，更通过保留观测数据内在的噪声关联特征，避免了过度去噪导致的物理信息损失，使模型在加速收敛的同时维持了对黑洞图像本征结构的精准建模能力，为平衡计算效率与物理真实性提供了新的技术路径。

在数据构建策略方面，面对黑洞观测数据稀缺的挑战，可以尝试构建融合多维度噪声特征的混合数据集。一方面仿照已有研究，使用磁流体力学模拟的高保真黑洞图像数据作为原始数据，另一方面使用真实的射电望远镜数据以获取现实中的噪声分布。在清晰的原始数据基础上，除了加入热电子噪声、天空背景噪声、人为射频干扰以及系统误差等原因产生的随机噪声外，还可以加入由理论计算模拟可能产生的旁瓣伪影作为干扰。这种基于物理机制与实测数据双重驱动的数据增强方法，突破了传统人工噪声合成的局限性，使得扩散模型在训练过程中能够充分学习真实观测环境下的噪声耦合规律，从而显著提升了对复杂天文噪声的解析能力，为模型在实测数据中的鲁棒泛化奠定了坚实的物理基础。

7.3 未来展望

7.3.1 大模型在黑洞研究的潜力

大模型凭借其高维特征提取能力，可对多波段观测数据（从射电到 X 射线）进行跨尺度关联，在看似无序的能谱波动中捕捉时空涟漪的深层模式，甚至通过模拟数十亿次粒子碰撞轨迹，重构出传统流体力学方程难以描述的吸积盘湍流结构。

这种智能系统展现的独特价值，在于其能构建多维参数空间的"数字孪生黑洞"。通过融合广义相对论方程、量子场论原理与真实观测数据，大模型不仅能加速百万核级别数值相对论模拟，更可探索传统物理直觉未曾抵达的领域——例如在极端旋转参数下时空奇点的可能形态，或通过逆向推演伽马射线暴的偏振特征，揭示原初黑洞诞生的初始条件。其生成式推理能力甚至可对事件视界望远镜未能完全解析的阴影轮廓进行超分辨率重建，在亚像素级别还原时空漩涡的精细结构。

7.3.2 大模型面临的挑战

尽管深度学习技术的应用和发展已经相当完善，但依然将深度学习模型应用在去噪、超分辨率方面依然存在一定的风险，研究者需要注意大模型的可解释性及其幻觉问题。大模型幻觉主要表现为深度学习模型生成内容与实际不符，或与给出数据不一致等情况。另外也有研究表明使用 Res-Net 模型进行降噪，但模型在图像形态学特征上产生了过拟合，并没有学习到实际的物理特征（如流体模拟等）。因此研究者要从多方面验证大模型的可行性与可解释性。

在研究开始阶段，为了快速确定机器学习/深度学习在黑洞方面的应用领域，团队利用多类大语言模型，通过特定的 Prompt，基于当前深度学习在应用性、可行性，以生成多个黑洞天文学领域的子研究主题。对比模型有：GPT-4o、Llama-3.1-405B、Qwen2-72B-Instruct-T、文心一言 3.5 和 GPT o1-mini 等。相关提示词工程已放在飞桨 AI Studio 上：<https://aistudio.baidu.com/projectdetail/8542897>。上述 LLM 均在相关 benchmark 上有很好的性能，DeepSeek-V3 的技术报告[61]也有相关部分体现：




图 5 选取的 LLM 在部分 benchmark 上的评测

（图片来源 DeepSeek-V3 技术报告）

我们通过调整 prompt，使得模型更能适配天文学子主题输出的任务，最终，各模型在不同子领域的研究方向各有侧重，其中，GPT-4o 主要输出引力波检测与分类、宇宙大尺度结构演化以及恒星光谱特征识别。Llama-3.1-405B 侧重于星系形态分类和特征提取，还列举检测和分类快速射电暴，同时支持行星轨道预测和稳定性分析。Qwen2-72B-Instruct-T 研究星系形态分类与演化，并参与超新星爆发的预测与分析，此外还用于引力波信号的检测与源定位。具体结果如下表：

表 4 各类大模型输出的子领域展示

模型	子领域 1	子领域 2	子领域 3	子领域 4	子领域 5
GPT-4o	引力波检测和分	宇宙大尺度结	识别恒星的光	识别快速射电暴	分析系外行星
	类	构演化	谱特征	（FRB）事件	的潜在宜居性
文心一言 3.5	星系分类与识别	暗物质与暗能	射电天文数据	天体物理现象预	天文学数据的
		量的探测与研	处理与分析	测与模拟	交叉验证与融
		究			合

	星系形态分类和	快速射电暴检	行星轨道预测	天文学数据质量	恒星演化模型
Llama-3.1-405B	特征提取	测检测和分类	和稳定性分析	控制	和爆炸机制研究
Qwen2-72B-Instruct-T	星系形态分类与演化研究	超新星爆发的预测与分析	引力波信号的检测与源定位	恒星和行星大气的光谱分析	天文学数据的交叉验证与融合
ChatGPT o1-mini	基于深度学习的星系形态自动分类与演化研究（CNN+时序网络）	引力波信号的深度学习检测与源源识别	多波段天文数据融合与异常检测（AE+GAN）	宇宙大尺度结构的机器学习模拟与预测（生成对抗网络+强化学习）	天文图像去噪与超分辨率重建（去噪自编码器+物理模型约束）

此外，团队对于相关论文的搜寻也一定程度上借助了 LLM 进行搜索，但是由于通用 LLM 的论文搜寻和推荐能力不过完善，这里相关的工作内容不做展示，具体可查看提供的飞桨项目链接：<https://aistudio.baidu.com/projectdetail/8542897>

8.2 借助 ChatPDF 理解论文/Prompt pipeline

这一部分展示通过 AI 大模型工具进行论文内容快速理解，具体演示项目链接为：<https://aistudio.baidu.com/projectdetail/8783755>。当前用于论文阅读理解的工具多种多样，如 DocsGPT，可基于提供的论文对特定模型进行训练微调，以此更好捕捉文章内容，但是因为不是免费，所以，本节选取另一个工具 ChatPDF 进行简要展示，同时，在本节，我们还提供了一个便于论文理解的 prompt pipeline，供读者参考。

ChatPDF 是一个能够从 PDF 文件中快速提取有用信息，并通过 ChatGPT 来解读这些信息的 AI 工具。ChatPDF 首先读取 PDF 文件，将其转换为可处理的文本格式，例如 txt 格式。接着，ChatPDF 会对提取出来的文本进行清理和标准化，例如去除特殊字符、分段、分句等，以便于后续处理。这一步可以使用自然语言处理技术，如正则表达式等。ChatPDF 使用 OpenAI 的 Embeddings API 将每个分段转换为向量，这个向量将对文本中的语义进行编码，以便于与问题的向量进行比较。当用户提出问题时，ChatPDF 使用 OpenAI 的 Embeddings API 将问题转换为一个向量，并与每个分段的向量进行比

较，以找到最相似的分段。这个相似度计算可以使用余弦相似度等常见的方法进行。ChatPDF 将找到的最相似的分段与问题作为 prompt，调用 OpenAI 的 Completion API，让 ChatGPT 学习分段内容后，再回答对应的问题。最后，ChatPDF 会将 ChatGPT 生成的答案返回给用户，完成一次查询。

下文以一篇 ICLR 2025，有关多模态大模型提升图像细粒度理解的论文[62]为例子，进行详细演示说明

ChatPDF 链接: <https://www.chatpdf.com/zh>

论文链接: <https://openreview.net/forum?id=p3NKpom1VL>

8.2.1 导入 PDF 文件

ChatPDF 允许用户上传待识别论文，基于其提供的大模型进行识别分析。上传后，会看到一个聊天窗口，里面有一段欢迎文字，主要是对 PDF 文件进行摘要，并给出一些可能感兴趣的问题。

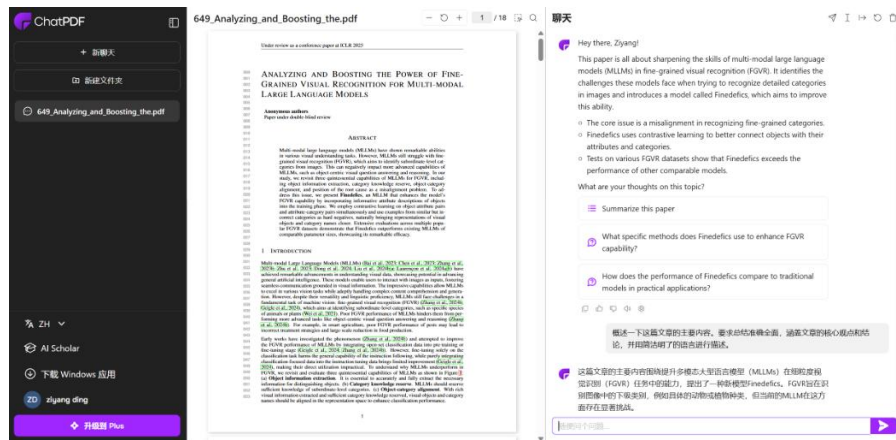


图 6 ChatPDF 聊天界面

8.2.2 构建 prompt pipeline

团队经过会议商讨，决定将理解论文分为以下几个模块去进行理解：

1. **主要内容：**为了总体对论文大意进行理解，需要最开始让 ChatPDF 输出总体认知；
2. **研究问题：**首先理解这篇论文着手于解决何种问题，了解当前行业动向，为自己的研究方向和创新点突破提供参考，同时也为进一步理解论文深度做好准备；

3. **模型整体架构：**对于深度学习相关的论文，最核心的在于理解论文的模型设计，因此，此部分需要花费大篇幅进行深度了解；
4. **部分框架说明：**这部分 Prompt 用于解决模型解释不清/理解不够的模块
5. **性能测试：**这部分用于理解论文中的实验部分，请详细知晓模型的性能
6. **研究结论和局部展望：**这部分用于理解模型的价值和未来改进之处

因而，团队提出以下 prompt 流程：

表 5 Prompt pipeline

输出方面	Prompt
1. 主要内容	概述一下这篇文章的主要内容。要求总结准确全面，涵盖文章的核心观点和结论，并用简洁明了的语言进行描述。
2. 研究问题	请说明该篇文章主要研究的核心问题是什么，并简要概述作者为何选择研究这个问题，以及该问题在该领域的重要性
3. 模型整体架构	首先再仔细阅读论文提出的或者使用的深度学习/机器学习模型，并深入理解。之后对整个模型进行一个详细的解读
4. 部分框架说明	我对于模型解读中的<模块>理解不清，请重新针对这一部分对我进行讲解。注意，我对这部分深度学习知识可能理解不够，需要解释相关术语。
5. 性能测试	请再仔细阅读论文进行的模型实验，并深入理解。之后对论文中的实验提供解读，要包括实验目的，所用的基准数据集，对比的其他模型效果，自己模型的效果等等。
6. 研究结论和局部展望	请说明该篇文章的研究结论和研究局限性，并简要讨论作者对未来研究的展望。具体包括研究中存在的主要限制、这些限制对结果的影响，以及作者建议的未来研究方向和可能的改进措施。

下面是使用过程中的部分简要演示：

1.

用户:

概述一下这篇文章的主要内容，要求在轮廓全面、清晰的基础上，通篇文章的观点和结论，并用简明的语言进行描述。

大模型:

这篇文章的主要内容讨论了多模态语言模型（MLMs）在细粒度视觉认知（FGVR）中的应用，提出了一种新的 Fine-tuned 方法。FGVR 在模型评估中被广泛应用，虽然 MLMs 在某些方面表现优异，但模型的调整和改进仍是必要的。

文章中的讨论包括：

1. 问题识别：MLMs 在 FGVR 中的表现不是理想，原因在于模型存在一些常见的限制，导致其在复杂任务中表现不如传统方法。
2. 方法创新：为了解决 MLMs 的不足，文章提出了一种基于 Fine-tuned 的方法，Fine-tuned 模型针对特定任务进行了优化，从而在性能上超越了原始的 MLMs。
3. 训练结果：Fine-tuned 模型通过不同的训练方法，展现了其在多个任务中的优势。训练过程中，通过数据的调整和方法的改进，Fine-tuned 模型的表现明显优于未调优的原始模型。
4. 实验分析：该实验对 Fine-tuned 方法的效果进行了验证，显示其在多项任务中明显优于未调优的 MLMs，进一步证明 Fine-tuned 技术对视觉任务的提升效果。

2.

用户:

请问这篇文章主要讲的是什么？并阐述其在相关研究中的作用，以及该问题的创新性

大模型:

这篇文章主要讨论了大规模语言模型（MLMs）在细粒度视觉识别（FGVR）中的应用。提出了针对 Fine-tuned 模型（FTs）的创新方法，并评估了这种方法在复杂视觉任务中的有效性。文章探讨了如何利用现有的技术进行改进，并且重点关注了模型的可解释性和应用性。

研究方法:

采用以下两种方法来评估 Fine-tuned 模型：

1. 问题识别：针对当前 MLMs 在 FGVR 中的表现问题，提出了 Fine-tuned 方法来解

决识别问题的不足，确保了 Fine-tuned 模型在多项任务中的有效性和准确性。

2. 解决方案: Fine-tuned 模型通过增强训练和优化策略，突破了传统 MLMs 模型的局限性，尤其在面临具有挑战性的复杂任务时，表现出了极高的潜力。

3. 训练过程: 通过训练 Fine-tuned 模型并对比原始模型，文章分析了在不同数据集上的表现差异，并展示了 Fine-tuned 方法在精准度、效率等方面的提升。

3.

用户:

首先再仔细阅读论文提出的或者使用的深度学习机器学习模型，并深入理解。之后对整个模型进行一个详细的解读

大模型:

论文中提出的模型为 Finedefics，它是一种多模态大型语言模型（MLLM），旨在帮助模型在程序或数据驱动器（FOVR）任务中的实现。以下是对 Finedefics 模型的详细解读:

1. 模型背景与动机

- 模型需要识别到图像的类别和目标符号，然后当前的 MLLM 在这方面表现不理想。其根本原因是：模型本身是一个方向。
- 物体信息模型：模型未能准确和全面提取区分不同对象所需的信息。
- 类别知识储备：模型缺乏足够的不可感知知识。
- 物体-类别开发：模型对物体和类别的存储无须简单的对齐存在，这影响了分类性能。

2. Finedefics 模型结构

- Finedefics 模型由 Idefic3（相关文献）扩展而来，专门针对 FOVR 能力进行了优化。

2.1 输入模块

- Finedefics 模型分别被定义为三种输入：
- 模型对象：输入图像中的目标物体信息。
- 属性描述：将模型对象的属性描述作为属性值，如颜色、形状等。

- 类别名称：下表是别的名称，用于对图像中的对象进行分类。

2.2 表示学习模块

- 模型通过不同的输入层分别处理上述三种输入。在处理完成后，从最后一层提取全部表示（global representation），这一过程帮助模型理解和插入之间的关系。

2.3 对比学习

- 在 Finedefics 中，采用对比学习策略：
 - 物体-属性：对来自同一对象的属性描述进行对比学习，以使其在表示学习中做出贡献。
 - 属性-类别开发：通过属性描述与类别名称对比，进一步增强这种对齐。
 - 属性-对象开发：引入与属性类型相关的属性对象为对象，使得模型在训练过程中更加专注于区分物体的类别差异。

3. 训练过程

- Finedefics 的训练过程包含两个主要阶段：
 1. 开放性和自适应 FOVR 建模训练：使用包含广泛类别的训练数据，以增强模型对不同类别的识别能力。
 2. 抽象训练：通过对方法进行抽象的训练，使得模型能够在任务中生成复杂且主观能量的结果。

4. 性能评估

- Finedefics 在多个流行的 FOVR 数据集上进行了广泛的评估，实验结果表明，该模型在 FOVR 任务中获得类似于其他相似参数的 MLLM，提出了更高的 Idefic32B(Down-VL-Chat 模型，Finedefics 表现出显著的性能提升（平均超过 10%）。

5. 结论与未来工作

- 研究表明，Finedefics 通过测试模型对所有对象进行了模型的 FOVR 能力，为了应对不同类别的学习挑战，未来的研究工作将聚焦于设计能够提高模型持续 FOVR 能力的领域。

6. 综述

- Finedefics 模型通过引入物体属性描述和对比学习策略，成功地破解了多模态大型语言模型在程序或数据驱动器任务中的问题。通过优化表示学习和增强物体-类别开发，模型建立了卓越的性能，这一研究为进一步探索 MLLM 在程序或任务中的应

用提供了新的新知识和支持。

4.

用户:

我对于模型解读中的困难负样本理解不清，请重新针对这一部分对我进行讲解。

注意，我对这部分深度学习知识可能理解不够，需要解释相关术语。

大模型:

当然可以！让我们详细解析 Finedefics 模型中的困难负样本（hard negatives）的概念，并解释相关术语。

1. 什么是负样本？

在机器学习和深度学习中，样本是指你用于训练模型的数据。样本可以分为两类：

- ****正样本** (positive samples)**：这些是模型应该关注和学习的样本，即正确的类或标签。

- ****负样本** (negative samples)**：这些是与正样本不对应的样本，即模型不应该选择它们的类或标签。

在 Finedefics 中，负样本主要是指与输入的视觉对象（如图像中的大类）对应但不正确的类别名称（如将“金毛猫”描述为“拉布拉多”）。

2. 什么是困难负样本？

困难负样本是指负样本中那些与正样本在特征上非常接近的样本。换句话说，困难负样本与正样本有着相似的外观或特征，但它们并不是正确的类别。

例如，如果你有一个关于“金毛猫”的正样本，那么“拉布拉多”可能就是一个困难负样本，因为两者在外观上非常相似，模型可能会容易混淆它们。

3. 为什么使用困难负样本？

使用困难负样本的主要原因是增强模型的区分能力。通过训练过程中引入困难负样本，模型能够：

- ****更好地学习边界****：模型将被归类为更加复杂的特征，以便能够区分非常相似的正样本和负样本。例如，在金毛犬和拉布拉多之间能够做出更精确的判断。

- ****提高准确率****：当模型在训练时面对这些接近的负样本时，它能自动降低自己的分类能力，提升其真实数据上的表现。

- **防止过拟合**：如果模型只学习容易区分的样本，它可能在新样本面前变得脆弱。困难负样本的引入可以帮助模型在更广泛的条件下建立更鲁棒的识别能力。

4. 在 Finedefics 中的应用

在 Finedefics 模型中，困难负样本的引入有助于解决物体-类别对齐问题。通过将正样本和困难负样本同时放入对比学习过程中，模型能够在同一训练步骤中优化其表示，使得不同类别之间的距离进一步拉开，从而实现更准确的分类。

具体实施方法是，模型在训练时，不仅要记住哪些是正确的类别，还要学习到为什么某些相似的类别（困难负样本）并不正确。这种过程有效帮助模型在面对真实世界数据时做出更准确的判断。

总结

- **负样本**指的是与正样本不对应的数据，而困难负样本更是与正样本特征相似且依然不正确的样本。

- 引入困难负样本可以提升模型区分相似类别的能力，优化物体-类别之间的对齐效果，从而提高整体识别精度。

希望这样的解释能够帮助你更好地理解困难负样本的概念和它在 Finedefics 模型中的重要性！如果你有进一步的问题，欢迎继续提问。

概述一下这篇文章的主要内容。要求总结准确全面，涵盖文章的核心观点和结论，并用简洁明了的语言进行描述。

请说明该篇文章主要研究的核心问题是什么，并简要概述作者为何选择研究这个问题，以及该问题在该领域的重要性。

这篇文章的主要内容围绕提升多模态大型语言模型（MLLMs）在细粒度视觉识别（FGVR）任务中的能力。提出了一种新模型Finedefics，FGVR旨在识别图像中的下级类别，例如具体的动物或植物种类，但当前的MLLM在这方面存在显著挑战。

文章的核心观点和结论包括：

- 问题识别**：MLLMs在FGVR中的表现不佳的根本原因在于视觉对象和类别名称之间存在不匹配。具体分析了三种基本能力的不足，包括物体信息提取、类别知识储备和物体-类别对齐。
- 方法创新**：为了解决上述问题，文章提出了Finedefics，该模型通过整合物体的属性描述来增强FGVR能力。通过对物体-属性对和属性-类别对齐进行对比学习，同时使用来自相似但错误类别的难例，Finedefics能够更好地对齐视觉对象和类别名称。
- 实验验证**：在多个流行的FGVR数据集上进行了广泛的评估，结果表明Finedefics在与其他相似参数的MLLMs相比，表现出显著的性能提升，平均提升幅度超过10%。
- 训练策略**：Finedefics的训练采用了两阶段的方法，通过属性增强对齐来提高模型的能力，而不仅仅是依赖于额外的数据微调。实验证明，这种方法有效地增强了模型的FGVR准确性。

总而言之，该研究不仅分析了MLLM在FGVR中的表现障碍，还提出了创新的解决方案，并通过实验证明了新方法的有效性，展示了Finedefics在细粒度视觉识别任务中的卓越表现。

📄 📌 🗑️ 🔄 📧

该篇文章主要研究的核心问题是多模态大型语言模型（MLLMs）在细粒度视觉识别（FGVR）任务中的表现不佳，特别是在模型在识别复杂图像中的下级类别（如特定动物或植物种类）时面临的挑战。

研究动机：

作者选择研究这一问题的原因包括：

- 应用的重要性**：细粒度视觉识别在许多实际应用中至关重要，例如智能农业中的害虫识别，这直接影响到农业生产和资源管理。准确识别细微类别的能力能够促进更高效的决策和策略制定。
- 现存局限性**：尽管MLLM在处理视觉任务方面取得了显著进展，但它们在FGVR任务中仍然表现不佳，限制了其在更复杂任务（如基于物体的视觉问答和推理）中的应用。

重要性：

该核心问题在多模态学习领域的重要性体现在以下几个方面：

- 理解视觉数据的能力提升**：提高FGVR性能能够增强模型对视觉数据的理解能力，推动人工智能走向更复杂的任务。
- 跨领域应用**：具备良好细粒度识别能力的模型能够更好地适应不同领域的需求，例如生态监测、自动化系统等。
- 基础理论的发展**：研究FGVR还有助于揭示模型在视觉理解过程中的基本机制，改善模型架构和训练方法，从而进一步促进多模态学习技术的发展。

总体而言，解决MLLM在FGVR中存在的问题，不仅能够推动相关技术的进步，也能提升模型在真实世界应用中的效用和可靠性。

📄 📌 🗑️ 🔄 📧

首先再仔细阅读论文提出的或者使用的深度学习/机器学习模型，并深入理解。之后对整个模型进行一个详细的解读

我对于模型解读中的困难负样本理解不清，请重新针对这一部分对我进行讲解。注意，我对这部分深度学习知识可能理解不够，需要解释相关术语。

论文中提出的模型为Finedefics，它是一种多模态大型语言模型（MLLM），旨在增强模型在细粒度视觉识别（FGVR）任务中的表现。以下是Finedefics模型的详细解读：

1. 模型背景与动机

细粒度视觉识别是识别细微类别的重要任务，然而当前的MLLM在这方面表现不够理想。其根本原因主要体现在三个方面：

- 物体信息提取：模型未能准确和全面提取区分不同对象所需的信息。
- 类别知识储备：模型缺乏足够的下级类别知识。
- 物体-类别对齐：视觉对象和类别名称在表示空间中的对齐不佳，这影响了分类性能。

2. Finedefics模型结构

Finedefics模型自Idefix2（相关文献）扩展而来，专门针对FGVR能力进行了优化。

2.1 输入模块

Finedefics模型分别接收以下三种输入：

- 视觉对象：输入图像中的具体物体信息。
- 属性描述：与视觉对象相关的具有描述性的属性信息，如颜色、形状等。
- 类别名称：下级类别的名称，用于对图像中的对象进行分类。

2.2 表示学习模块

模型通过不同的输入层分别处理上述三种输入。在处理完成后，从最后一层提取全局表示（global representations），这一过程帮助模型理解不同输入之间的关系。

2.3 对比学习

在Finedefics中，采用对比学习策略：

- 物体-属性对：对来自同一对象的视觉属性描述进行对比学习，以使其在表示空间中彼此靠近。
- 属性-类别对：通过将属性描述与类别名称对比，进一步增强这种对齐。
- 困难负样本：引入与正确类别相似但错误的类别作为负样本，使得模型在训练过程中更加专注于区分微小的类别差异。

3. 训练过程

Finedefics的训练过程包含两个主要阶段：

- 开放集和闭合集FGVR数据训练：使用包含广泛类别的训练数据，以增强模型对不同类别的识别能力。
- 指令微调：通过对比过程进行细致的微调，使得模型能够在任务特定数据集上实现更好的表现。

4. 性能评估

Finedefics在多个流行的FGVR数据集上进行了广泛的评估。实验结果表明，该模型在FGVR任务中的表现优于其他相似参数的MLLM，相比于现有的Idefix2和Qwen-VL-Chat模型，Finedefics表现出显著的性能提升（平均超过10%）。

5. 结论与未来工作

研究表明，Finedefics通过属性增强对齐有效提升了模型的FGVR能力。为了应对新下级类别的学习挑战，未来的研究工作将聚焦于设计能够提高模型持续FGVR能力的微调方法。

综述

Finedefics模型通过引入物体属性描述和对比学习策略，成功地缓解了多模态大型语言模型在细粒度视觉识别任务中面临的困难。通过优化表示学习和增强物体-类别对齐，表现出了卓越的性能。这一研究为进一步探索MLLM在细粒度任务中的应用提供了新思路 and 实证支持。

📄 🗨️ 🔄 📊 📌

当然可以！让我们详细解析Finedefics模型中的**困难负样本**（hard negatives）的概念，并解释相关术语。

1. 什么是负样本？

在机器学习和深度学习中心，**样本**是指你用于训练模型的数据。样本可以分为两类：

- 正样本**（positive samples）：这些是模型应该关注和学习样本，即正确的类别或标签。
- 负样本**（negative samples）：这些是与正样本不对应的样本，即模型不应该选择它们的类别或标签。

在Finedefics中，**负样本**主要是指与输入的视觉对象（如图像中的犬类）对应但不正确的类别名称（如将“金毛猎犬”错误标记为“拉布拉多”）。

2. 什么是困难负样本？

困难负样本是指负样本中那些与正样本在特征上非常接近的样本。换句话说，困难负样本与正样本有着相似的外观或特征，但它们并不是正确的类别。

例如，如果你有一个关于“金毛猎犬”的正样本，那么“拉布拉多犬”可能就是一个困难负样本，因为两者在外观上非常相似，模型可能会容易混淆它们。

3. 为什么使用困难负样本？

使用困难负样本的主要原因是**增强模型的区分能力**。通过在训练过程中引入困难负样本，模型能够：

- 更好地学习边界**：模型将被迫学习更加复杂的特征，以便能够区分非常相似的正样本和负样本。例如，在金毛犬和拉布拉多犬之间能够做出更精确的判断。
- 提高准确率**：当模型在训练时面对这些接近的负样本时，它能互动磨练自己的分类能力，提升在真实数据上的表现。
- 防止过拟合**：如果模型只学习容易区分的样本，它可能在新样本面前变得脆弱。困难负样本的引入可以帮助模型在更广泛的条件下建立更鲁棒的识别能力。

4. 在Finedefics中的应用

在Finedefics模型中，困难负样本的引入有助于解决**物体-类别对齐**问题。通过将正样本和困难负样本同时放入对比学习过程中，模型能够在同一训练步骤中优化其表示，使得不同类别之间的距离进一步拉开，从而实现更准确的分类。

具体实施方式是，模型在训练时，不仅要记住哪些是正确的类别，还要学习到为什么某些相似的类别（困难负样本）并不正确。这种过程有效帮助模型在面对真实世界数据时做出更准确的判断。

总结

- 负样本**指的是与正样本不对应的数据，而**困难负样本**更是与正样本特征相似但依然不正确的样本。
- 引入困难负样本可以提升模型区分相似类别的能力，优化物体-类别之间的对齐效果，从而提高整体识别精度。

希望这样的解释能够帮助你更好地理解困难负样本的概念和它在Finedefics模型中的重要性！如果你有进一步的问题，欢迎继续提问。

图 7 ChatPDF 基于 prompt pipeline 的部分输出示例

8.3 各领域论文汇总

团队使用上述论文阅读辅助方法和 prompt pipeline 等，快速总结了各个子领域的论文情况。团队基于 Flowus、Notion 等软件，协作撰写了不同黑洞子领域下，机器学习/深度学习应用的相关论文，总数为 40 篇，具有了一定的论文数量规模。团队对每一篇论文的分析做出详细格式要求，包括：**整理人、年份、来源、作者、所用机器学习/深度学习、模型理解、黑洞相关任务、模型效果、创新性尝试、较前人改进、是否是基于之前论文的改进、大模型辅助记录（记录所有 prompt 等）**。上述方面能够有效理解一篇论文的大意。

其中，FlowUs 协作文档链接：<https://flowus.cn/share/a84c6f78-0f8c-457e-b44b-3f5910e3fdbbe?code=G4GF9P> 引力波信号去噪和检测的 2020-2025 年文献梳理工作链接如下：<https://free-ironclad-6dc.notion.site/178d4225066880fda8c9ce640b2bb90d?pvs=74>。下

面是一些页面截图：

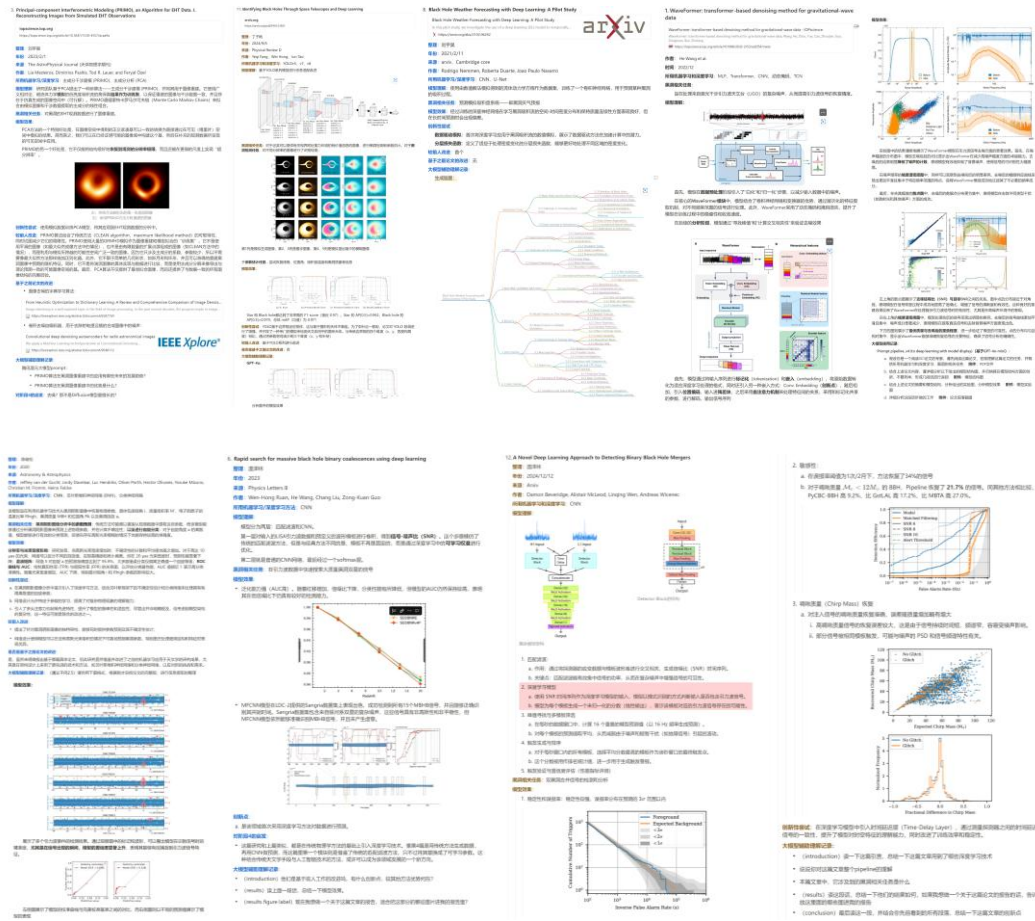


图 8 Flowus 和 Notion 汇总的部分论文分析示例

8.4 思维导图生成

团队基于 QQ 浏览器内置的 AI 助手（腾讯混元大模型提供支持），进行了论文思维导图的生成，以此来辅助理解论文架构

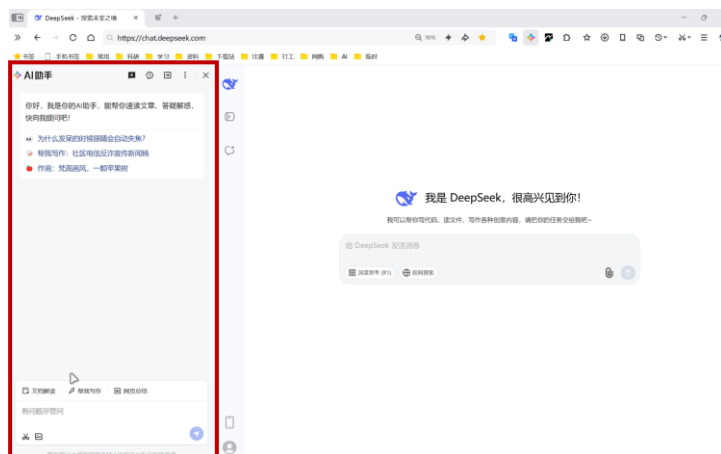


图 9 QQ 浏览器 AI 助手

导入论文的 pdf 文件后，输入以下 prompt 便可以进行思维导图的生成：



参考文献

- [1] Oppenheimer J R, Volkoff G M. On Massive Neutron Cores[J]. Physical Review, 1939, 55(4): 374-381.
- [2] Vesperini E, McMillan S L W, D’Ercole A, et al. INTERMEDIATE-MASS BLACK HOLES IN EARLY GLOBULAR CLUSTERS[J]. The Astrophysical Journal Letters, 2010, 713(1): L41.
- [3] Abramowicz M A, Fragile P C. Foundations of Black Hole Accretion Disk Theory[J]. Living Reviews in Relativity, 2013, 16(1): 1.
- [4] Shakura N I, Sunyaev R A. Black Holes in Binary Systems: Observational Appearances[J]. Symposium - International Astronomical Union, 1973, 55: 155-164.
- [5] Kozłowski M, Jaroszynski M. The analytic theory of fluid disks orbiting the Kerr black hole[J]. Astronomy and Astrophysics, [2025].
- [6] Abramowicz M A. Slim accretion disks[J]. Astrophysical Journal, [2025].
- [7] Narayan R, Yi I. Advection-Dominated Accretion: Self-Similarity and Bipolar Outflows[J]. The Astrophysical Journal, 1995, 444: 231.
- [8] Mirabel I F, Rodríguez L F. Sources of Relativistic Jets in the Galaxy[J]. Annual Review of Astronomy and Astrophysics, 1999, 37(1): 409-443.
- [9] Collaboration T L S, Aasi J, Abbott B P, et al. Advanced LIGO[J]. Classical and Quantum Gravity, 2015, 32(7): 074001.
- [10] Abbott B P, Abbott R, Abbott T D, et al. Observation of gravitational waves from a binary black hole merger[M]//Centennial of General Relativity. World Scientific Publishing Co. Pte. Ltd., 2017: 291-311.
- [11] Chan M L, Heng I S, Messenger C. Detection and classification of supernova gravitational wave signals: A deep learning approach[J]. Physical Review D, 2020, 102(4): 043022.
- [12] Thorne K S. Gravitational Waves[A]. arXiv, 1995.

- [13] Kokkotas K D. GRAVITATIONAL WAVE PHYSICS[J].
- [14] Berti E. Viewpoint: The First Sounds of Merging Black Holes[J]. Physics, 2016, 9: 17.
- [15] Weber J. Detection and Generation of Gravitational Waves[J]. Physical Review, 1960, 117(1): 306-313.
- [16] Pitkin M, Reid S, Rowan S, et al. Gravitational Wave Detection by Interferometry (Ground and Space)[J]. Living Reviews in Relativity, 2011, 14(1): 5.
- [17] Ju L, Blair D G, Zhao C. Detection of gravitational waves[J]. Reports on Progress in Physics, 2000, 63(9): 1317-1427.
- [18] Estabrook F B, Wahlquist H D. Response of Doppler spacecraft tracking to gravitational radiation[J]. General Relativity and Gravitation, 1975, 6(5): 439-447.
- [19] Oguri M. Effect of gravitational lensing on the distribution of gravitational waves from distant binary black hole mergers[J]. 2018.
- [20] Schmidt S, Breschi M, Gamba R, et al. Machine learning gravitational waves from binary black hole mergers[J]. Physical Review D, 2021, 103(4): 043020.
- [21] Raidal M, Vaskonen V, Veermäe H. Gravitational waves from primordial black hole mergers[J]. Journal of Cosmology and Astroparticle Physics, 2017, 2017(09): 037-037.
- [22] Collaboration T E H T. First M87 Event Horizon Telescope Results. I. The Shadow of the Supermassive Black Hole[J]. The Astrophysical Journal Letters, 2019, 875(1): L1.
- [23] Högbom J A. Aperture Synthesis with a Non-Regular Distribution of Interferometer Baselines[J]. Astronomy and Astrophysics Supplement: 417.
- [24] Maximum entropy image restoration in astronomy[EB/OL]. [2025-02-11]. <https://www.nature.com/articles/d44151-023-00175-0>.
- [25] Akiyama K, Chael A, Pesce D W. New Views of Black Holes from Computational Imaging[J]. Nature Computational Science, 2021, 1(5): 300-303.
- [26] Medeiros L, Psaltis D, Lauer T R, et al. The Image of the M87 Black Hole Reconstructed

with PRIMO[J]. The Astrophysical Journal Letters, 2023, 947(1): L7.

[27] Owen B J, Sathyaprakash B S. Matched filtering of gravitational waves from inspiraling compact binaries: Computational cost and template placement[J]. Physical Review D, 1999, 60(2): 022002.

[28] Virtuoso A, Milotti E. Wavelet-based tools to analyze, filter, and reconstruct transient gravitational-wave signals[J]. Physical Review D, 2024, 109(10): 102010.

[29] Adaptive filtering techniques for gravitational wave interferometric data: Removing long-term sinusoidal disturbances and oscillatory transients | Phys. Rev. D[EB/OL]. [2025-02-11]. <https://journals.aps.org/prd/abstract/10.1103/PhysRevD.63.042004>.

[30] Torres-Forné A, Marquina A, Font J A, et al. Denoising of gravitational wave signals via dictionary learning algorithms[J]. Physical Review D, 2016, 94(12): 124040.

[31] Wei W, Huerta E A. Gravitational wave denoising of binary black hole mergers with deep learning[J]. Physics Letters B, 2020, 800: 135081.

[32] Noise reduction in gravitational-wave data via deep learning | Phys. Rev. Research[EB/OL]. [2025-02-11]. <https://journals.aps.org/prresearch/abstract/10.1103/PhysRevResearch.2.033066>.

[33] Morales M D, Antelis J M, Moreno C, et al. Deep Learning for Gravitational-Wave Data Analysis: A Resampling White-Box Approach[J]. Sensors, 2021, 21(9): 3174.

[34] Lopac N, Hrzic F, Vuksanovic I P, et al. Detection of Non-Stationary GW Signals in High Noise From Cohen's Class of Time-Frequency Representations Using Deep Learning[J]. IEEE Access, 2022, 10: 2408-2428.

[35] Zhang H, Zhu Z, Fu M, et al. Gravitational Wave-Signal Recognition Model Based on Fourier Transform and Convolutional Neural Network[J]. Computational Intelligence and Neuroscience, 2022, 2022: 1-10.

[36] Detecting and denoising gravitational wave signals from binary black holes using deep learning | Phys. Rev. D[EB/OL]. [2025-02-11].

<https://journals.aps.org/prd/abstract/10.1103/PhysRevD.108.043024>.

[37] Bacon P, Trovato A, Beijer M. Denoising gravitational-wave signals from binary black holes with a dilated convolutional autoencoder[J]. Machine Learning: Science and Technology, 2023, 4(3): 035024.

[38] Reissel C, Soni S, Saleem M, et al. Coherence DeepClean: Toward autonomous denoising of gravitational-wave detector data[A]. arXiv, 2025.

[39] Nigam R, Mishra A, Reddy P. Transient Classification in low SNR Gravitational Wave data using Deep Learning[A]. arXiv, 2020.

[40] Extraction of binary black hole gravitational wave signals from detector data using deep learning | Phys. Rev. D[EB/OL]. [2025-02-11]. <https://journals.aps.org/prd/abstract/10.1103/PhysRevD.104.064046>.

[41] Detection of gravitational waves using Bayesian neural networks | Phys. Rev. D[EB/OL]. [2025-02-11]. <https://journals.aps.org/prd/abstract/10.1103/PhysRevD.103.063034>.

[42] WaveFormer: transformer-based denoising method for gravitational-wave data - IOPscience[EB/OL]. [2025-02-11]. <https://iopscience.iop.org/article/10.1088/2632-2153/ad2f54/meta#skip-to-content-link-target>.

[43] Space-based gravitational wave signal detection and extraction with deep neural network | Communications Physics[EB/OL]. [2025-02-11]. <https://www.nature.com/articles/s42005-023-01334-6>.

[44] Chatterjee C, Jani K. Reconstruction of binary black hole harmonics in LIGO using deep learning[J]. The Astrophysical Journal, 2024, 969(1): 25.

[45] Roscani V, Tozza S, Castellano M, et al. A comparative analysis of denoising algorithms for extragalactic imaging surveys[J]. Astronomy & Astrophysics, 2020, 643: A43.

[46] Starck J L, Bobin J. Astronomical Data Analysis and Sparsity: From Wavelets to Compressed Sensing[J]. Proceedings of the IEEE, 2010, 98(6): 1021-1030.

- [47] Gheller C, Vazza F. Convolutional deep denoising autoencoders for radio astronomical images[J]. Monthly Notices of the Royal Astronomical Society, 2021, 509(1): 990-1009.
- [48] Karras J. johannakarras/Deep-Neural-Networks-for-Black-Hole-Imaging[CP/OL]. (2024-08-23)[2025-02-11]. <https://github.com/johannakarras/Deep-Neural-Networks-for-Black-Hole-Imaging>.
- [49] Dax M, Green S R, Gair J, et al. Real-Time Gravitational Wave Science with Neural Posterior Estimation[J]. Physical Review Letters, 2021, 127(24): 241103.
- [50] Tabak E G, Vanden-Eijnden E. Density estimation by dual ascent of the log-likelihood[J]. Communications in Mathematical Sciences, 2010, 8(1): 217-233.
- [51] Du M, Liang B, Wang H, et al. Advancing Space-Based Gravitational Wave Astronomy: Rapid Parameter Estimation via Normalizing Flows[J]. Science China Physics, Mechanics & Astronomy, 2024, 67(3): 230412.
- [52] Lin J Y Y, Wong G N, Prather B S, et al. Feature Extraction on Synthetic Black Hole Images[A]. arXiv, 2020.
- [53] Zhang X T, Messenger C, Korsakova N, et al. Detecting Gravitational-waves from Extreme Mass Ratio Inspirals using Convolutional Neural Networks[J]. Physical Review D, 2022, 105(12): 123027.
- [54] Yun Q, Han W B, Guo Y Y, et al. The detection, extraction and parameter estimation of extreme-mass-ratio inspirals with deep learning[A]. arXiv, 2023.
- [55] Tuccillo D, Huertas-Company M, Decenci re E, et al. Deep learning for galaxy surface brightness profile fitting[J]. Monthly Notices of the Royal Astronomical Society, 2018, 475(1): 894-909.
- [56] Simonyan K, Zisserman A. Very Deep Convolutional Networks for Large-Scale Image Recognition[A]. arXiv, 2015.
- [57] Vaswani A, Shazeer N, Parmar N, et al. Attention is All you Need[J].

- [58] Zhao T, Lyu R, Wang H, et al. Space-based gravitational wave signal detection and extraction with deep neural network[J]. Communications Physics, 2023, 6(1): 212.
- [59] Ho J, Jain A, Abbeel P. Denoising Diffusion Probabilistic Models[J].
- [60] Naveed H, Khan A U, Qiu S, et al. A Comprehensive Overview of Large Language Models[A]. arXiv, 2024.
- [61] DeepSeek-AI, Liu A, Feng B, et al. DeepSeek-V3 Technical Report[A]. arXiv, 2024.
- [62] He H, Li G, Geng Z, et al. ANALYZING AND BOOSTING THE POWER OF FINE-GRAINED VISUAL RECOGNITION FOR MULTI-MODAL LARGE LANGUAGE MODELS[J]. 2025.